

ICS 35.210

YD

CCS L77

中华人民共和国通信行业标准

YD/T [×××××]—[××××]

智能体交付管理能力要求

Requirements for intelligent agent delivery management capability

[点击此处添加与国际标准一致性程度的标识]

(征求意见稿)

2025 年 1 月 10 日

[××××]—[××]—[××]发布

[××××]—[××]—[××]实施

中华人民共和国工业和信息化部 发布

目 次

1 范围	5
2 规范性引用文件	5
3 术语和定义	5
4 缩略语	5
5 智能体交付管理能力要求	5
6 部署前阶段	错误！未定义书签。
6.1 需求及方案	错误！未定义书签。
6.2 体系架构及数据准备	错误！未定义书签。
6.3 模型预训练及智能体策略设计	错误！未定义书签。
7 部署中阶段	错误！未定义书签。
7.1 开发及测试	错误！未定义书签。
7.2 部署及集成	错误！未定义书签。
8 部署后阶段	错误！未定义书签。
8.1 运维及监控	错误！未定义书签。
参 考 文 献	15

前 言

。

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。
本文件是 YD/T XXXXX-XXXX《智能体交付管理能力要求》，该标准的结构和名称预计如下：

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别这些专利的责任。

本文件由中国通信标准化协会提出并归口。

本文件起草单位：

本文件主要起草人：

仅限CCSA TC1 WG5标准起草组内使用 DO NOT COPY

引言

随着人工智能技术的蓬勃发展，智能体已然成为了诸多行业变革与创新的核心驱动力。无论是在智能家居系统中自动调控各类设备，使其契合用户的生活习惯；还是在智能交通领域，协助优化车流调度，缓解交通拥堵；亦或是在医疗场景下辅助医生进行精准诊断，智能体的身影无处不在，其应用范围不断拓展，应用深度也日益增加。

然而，智能体要想在这些复杂且多样化的场景中充分发挥自身优势，准确无误地履行职责、达成预期目标，就必须具备可靠且强大的交付能力。交付能力的强弱直接关系到智能体能否全面、及时、精准地获取外界环境的关键信息，这就如同航海中的灯塔，为智能体后续的决策与行动指明方向。

目前，智能体在不同应用场景下的表现参差不齐，部分由于交付管理能力不足而导致无法准确感知环境变化，进而出现决策失误、任务执行效果不佳等情况。鉴于此，制定统一且科学合理的智能体交付管理能力要求标准就显得至关重要了。它不仅能够规范智能体的研发与设计，确保其在诞生之初便具备合格的观测能力，还能为不同应用场景下衡量智能体的性能提供清晰的参照，帮助使用者筛选出最契合需求的智能体，同时也为智能体技术持续健康发展、不断拓展应用边界奠定坚实的基础，让智能体推动各行业高质量发展。

仅限CCSA TC1 WG5标准起草组内使用

智能体交付管理能力要求

1 范围

本文件规范了智能体交付管理能力要求，包括规划与准备、开发与测试、部署与上线、运行与改进四个阶段。

本文件适用于智能体服务和解决方案提供商，并为企业用户提供智能体产品选型借鉴和参考。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

3 术语和定义

下列术语和定义适用于本文件。

YD/T 1926.3-2010界定的以及下列术语和定义适用于本文件。

3.1

智能体 agent

智能体是一种能够感知环境、进行决策并执行动作的软件或实体，具备自主性、适应性、社会性和交互性等特点。本文件所定义的智能体是基于大语言模型的智能体。

4 缩略语

下列缩略语适用于本文件。

5 智能体交付管理能力

5.1 整体架构




图1 智能体交付管理能力框架图

5.2 规划与准备阶段

5.2.1 交付需求定义与指标体系设计

该阶段需明确任务目标与监管合规要求，预定义智能体全生命周期交付指标及技术栈。

5.2.1.1 业务目标与场景拆解

1) 目标拆解细化：在目标拆解时，需特别关注交付性目标。明确智能体在特定业务场景下的主要目标，并将其拆解为可量化、可追踪的子目标。对于每个子目标，必须定义清晰的交付指标，如响应时间、决策准确性、任务完成率等，并确保这些指标可在后续阶段进行实时监控和优化。

2) 关联业务流程：必须详细梳理智能体在各个关键业务流程中的具体作用，并建立其与相应任务目标之间的紧密、可量化的关联。以供应链管理智能体为例，需明确其在采购、仓储、配送等流程中，通过优化库存周转率、降低物流成本等手段，对成本控制目标的具体贡献数值。

5.2.1.2 监管合规

1) 法规政策收集：需全面地覆盖与智能体应用领域直接或间接相关的所有法律法规、行业标准以及监管政策，并实时更新。

2) 合规差距评估：需对照收集到的监管要求，对企业现有业务流程以及智能体初步设计方案进行细致、深入的合规差距评估。

3) 确认是否需要联动企业内部安全信息与事件管理类系统。

5.2.2 交付技术栈与工具选型

该阶段需通过数据日志与监控工具（如Data Catalog、Feature Store中嵌入监控）确保数据输入质量与可追溯性。

5.2.2.1 日志采集

选用如ELK (Elasticsearch + Logstash + Kibana) 等方案，或利用其他开源或云厂商提供的集中日志平台；

考虑多Agent环境时，需要支持灵活的标记和检索，能合并来自不同Agent、不同容器/节点的日志。

5.2.2.2 工具集成

分布式追踪与可视化

考虑使用 OpenTelemetry、Jaeger、Zipkin 等工具来实现跨服务/多 Agent 的调用链追踪；

在设计之初就规定分布式追踪的上下文 ID、Trace ID、Span ID 等注入与传递规范，确保后续具备良好的可追踪性。

监控系统与指标存储

常见技术栈如 Prometheus + Grafana，也可选用其他开源或云厂商方案；

根据业务规模确定指标数据的留存策略、采样率与历史归档方式。

5.2.2.3 合规与风险管理提前介入

明确相关行业法规 (xxx) 对数据采集和日志记录的限制与要求；

制定敏感数据的脱敏策略、访问控制策略，并预留相应的扩展性。

5.2.2.4 质量保障

5.2.3 组织与流程准备

5.3 开发与测试阶段

Agent 开发中引入 OpenTelemetry 埋点，对决策链、工具调用和检索等过程进行追踪；利用 CI/CD 将自动化测试与采集就绪，以确保 Agent 逻辑正确性和交付性在测试阶段已基本完善。

5.3.1 自动化测试与交付集成

5.3.1.1 功能测试与可解释性测试

- 验证 Agent 输出中间推理、决策原因等可解释性信息是否能正常记录到交付日志或数据库中。
- 多 Agent 协作开发场景，通过自动化测试脚本，涵盖 Agent 之间的消息联动与上下文传递；

5.3.1.2 负载与压力测试

- 通过工具 (JMeter 等) 模拟高并发、多 Agent 协同请求，验证系统在高压负载下的交付指标 (CPU/GPU 利用率、响应时间、错误率等)；

5.3.1.3 安全测试与审计验证

- 执行渗透测试、注入测试 (Prompt Injection、SQL 注入等)，确保交付系统能够记录并识别高危操作与异常行为；

- 对审计日志完整性进行校验，确认敏感操作均有交付轨迹且无法篡改。

5.3.2 开发环境与测试环境交付一致性

开发环境

- 在研发阶段启用基础的监控指标（日志、追踪、监控），开发者能及时发现与修复功能或性能问题；
- 保持与生产相似的交付配置，避免“在测试环境一切正常，生产环境交付失效”现象。

测试环境演练

- 用准生产环境进行交付功能演练，包括：
 - 故障注入（Chaos Engineering）测试；
 - 网络延迟或断开模拟；
 - 多 Agent 交互异常路径探测等。
- 验证各异常场景是否能被实时捕获并报警，日志是否足以溯源和排障。

5.3.3 模型预训练及智能体策略设计

结合评测框架（如 OpenAI Evals）与 MLOps 工具记录训练超参与评估指标，在策略设定与模型更新时，通过交付数据实现策略迭代与 A/B 对比评测的闭环管理。

5.3.3.1 指标采集

可利用 MLOps 工具，在模型训练的每一个阶段，同步记录由评测框架（如 OpenAI Evals）生成的评估指标，如准确率、召回率、F1 值、均方误差等，为后续的模型分析和策略调整提供详实的数据基础。

5.3.3.2 策略设置

5.3.3.3 模型更新

1) 触发条件设定：需明确模型更新的触发条件，这些条件可以基于评估指标的变化、新数据的积累量、时间周期等。当满足触发条件时，自动启动模型更新流程。

2) 更新机制实现：能实现模型更新的具体机制，包括重新加载最新数据、调整训练超参数、采用新的训练算法等，确保模型能够不断适应新的情况和数据变化。

5.3.3.4 策略迭代

能够根据 A/B 对比评测的结果，确定表现最优的策略，并将其应用到下一轮的模型训练和智能体策略调整中。同时，对其他策略进行分析和改进，形成一个不断迭代优化的闭环管理流程。

5.3.3.5 A/B 对比评测

定期或在特定事件触发时，能针对不同策略下的智能体表现进行 A/B 对比评测。通过将用户或测试数据随机分配到不同策略的智能体实例上，收集并对比它们的响应结果和性能指标。

5.4 部署与上线阶段

5.4.1 部署过程管理

5.4.1.1 CI/CD管理

- 在 CI/CD 中进行合规扫描、日志采集、构建产物溯源等，使部署过程透明化；
- 对智能体模型版本、依赖的第三方库版本及系统环境进行记录和可追踪，便于后续快速回退或审计。

5.4.1.2 灰度发布、A/B测试监控

- 在上线前或过程中，建议进行灰度发布策略，监测关键指标（响应时间、错误率、业务转化率等），确保无大规模故障再逐步扩大范围；
- A/B 测试场景下：对多个 Agent 或同一 Agent 的不同版本同时上线，通过统一的交付平台对比关键指标走势，及时发现优劣。

5.4.2 上线后监控与审计

5.4.2.1 多Agent调度与健康检查

- 部署时需确认每个 Agent 实例的健康状态，并建立自动化健康检查机制，及时识别因版本不兼容或配置不当导致的故障；
- 部署到 Kubernetes，利用 Pod 弹性伸缩（HPA、VPA）结合 Prometheus 数据进行动态资源调度。

5.4.2.2 合规复审与敏感操作监视

- 对新上线的 Agent 版本进行合规性检查，保证敏感调用或数据处理符合法规；
- 重点关注权限操作、隐私数据访问、外部 API 调用等场景，确保上线后实时日志及审计机制正常运行。

5.5 运行与改进阶段

5.5.1 行为追踪与性能度量

5.5.1.1 分布式追踪全链路可视化

- 对用户→Agent→外部服务（API、数据库、工具等）的调用进行跨组件追踪；
- 针对多 Agent 协作，提供统一的跨 Agent 关联 ID 或会话 ID，方便后续协作排障和性能瓶颈排查。

5.5.1.2 性能度量与瓶颈识别

- 定期收集响应时间分布、吞吐量、队列长度、资源占用（CPU/GPU 内存）、调用超时率等；
- 配置实时告警（如 Grafana）和历史趋势分析，识别发生性能退化的 Agent 或节点，自动化触发扩容或告警。

5.5.2 质量与决策评估

5.5.2.1 实时用户反馈及数据回流

- 收集用户评分、人工审核意见、异常用例等，构建在线或离线的评估系统，帮助衡量当前 Agent 版本的准确度、逻辑一致性、可解释性等；

- 针对多轮对话或复杂任务执行，结合上下文日志追踪，定位是否存在回答不一致或状态混乱。

5.5.2.2 决策可解释性与审计

- 为合规或业务需求较高的场景，保留 Agent 推理路径、置信度评分、关键引用文档或知识库链接等信息；
- 在事后审计或异常排查中，根据可解释性记录，迅速判断决策是否合理、来源是否可信。

5.5.3 安全合规与智能策略优化

5.5.3.1 持续安全监控与异常检测

- 出现重大安全或合规事件时，提供快速下线或回滚功能，阻断潜在的系统风险。
- 建议构建异常检测模型或规则，以识别疑似攻击、异常高频调用、越权访问、数据泄露等；

5.5.3.2 自动化策略迭代与 A/B 实验

- 通过 A/B 试验或多版本对照，验证优化策略对关键指标（成功率、故障率等）的影响。
- 建议将交付数据与在线学习、强化学习或 MLOps 结合，进行 Agent 策略或模型的自动迭代；

5.5.3.3 版本管理与生命周期规划

- 结合业务反馈，对现有 Agent 版本进行维护、升级或退役；
- 对老版本数据、日志进行归档和存储，以备日后审计或再分析时使用；
- 当合规政策或业务需求大幅变化时，触发外循环层面的重大版本或架构重构。

6 全生命周期交付能力评估

6.1 能力矩阵

6.2 运维及监控交付指标

围绕行为追踪、性能度量、质量与策略评估、安全合规维度，进行运维监控告警、自动化生成报表。指导问题定位、性能调优。

6.1.1 行为追踪

1) 全生命周期与版本管理追踪

- 应记录并关联 Agent 的版本信息、模型迭代历史和配置变更日志，使得在不同版本切换或回滚时能够准确地追溯行为差异。
- 建议在每次部署或热更新时打上“版本标识”，便于在后续出现问题时快速确定受影响的范围与具体版本。

2) 多 Agent 协作场景下的调用链路监控

- 应支持对多 Agent 之间的相互调用、消息传递和上下文共享进行可视化跟踪，例如通过会话 ID 或协作 ID 统一标记，使跨 Agent 的行为路径可被串联查看。
- 对于大规模 Agent 集群协同处理任务，建议建立分布式追踪系统（如 OpenTelemetry、Jaeger）并结合统一的索引和搜索服务。

3) 可解释与可理解性的行为记录

- 在关键决策节点，应可选地记录 Agent 的推理理由、证据或评分等中间解释信息，帮助开发者和审计人员理解决策背后的逻辑。
- 对于需要满足可解释 AI 要求的场景，可将解释性数据以结构化或可视化形式展示，并保留在追踪日志中以供事后分析。

4) 实时与历史回溯功能

- 应提供实时的调用监控和可视化看板，支持多维度的筛选条件（时间、Agent 版本、场景、节点等）。
- 对追踪数据进行存档和索引后，便于在运维或审计环节进行历史回溯与深度排查，结合外部日志（如系统日志、网络日志）进行综合分析。

6.1.2 性能度量

1) 关键资源与应用层指标的全面采集

- 应监控 CPU、GPU、内存、网络带宽等基础资源利用率，并记录峰值、平均值、抖动情况；
- 针对应用层的性能指标，除传统的响应时间、吞吐量、错误率外，还可进一步细分为：
 - 外部工具/知识库调用成功率与平均耗时，用于衡量 Agent 对外部资源的依赖性能；
 - 多轮交互成功率（在多轮对话或多步任务中，Agent 能否持续保持上下文一致并正确完成目标）；
 - 队列积压与任务执行等待时长（在多 Agent 或高并发场景中，任务调度效率的体现）。

2) 多 Agent 协同性能分析

- 在多 Agent 并行或分层调用的场景下，应能细分并统计各个 Agent 在协作中的处理耗时与资源占用，以识别瓶颈环节；
- 建议为每个 Agent 分配独立或隔离的监控视图，并能在统一平台上聚合展示，以便快速对比、分析。
- 任务调度延迟（Agent 间任务传递耗时）

6.1.3 质量与策略评估

1) 全流程质量检查与自动化测试

- 在 Agent 开发与测试阶段，应通过自动化测试框架（如 OpenAI Evals）对回答准确性、逻辑一致性、完成度等进行评估；
- 建议设计针对多场景、多样本的测试集，涵盖常见用例、边界情况与恶意输入，以便发现模型在极端场景下的表现缺陷。
- 知识库引用覆盖率（如“回答中引用的知识片段占比 $\geq 80\%$ ”）。

2) 多维决策指标与解释性

- 应在 Agent 决策过程中记录关联信息，包括主要证据、候选选项的置信度、最终决策的理由等，以便评估其可解释性和合理性；
- 可引入定性和定量相结合的指标：
 - 定量指标如：回答准确率、关键词匹配度、用户满意度评分；
 - 定性指标如：审阅专家对 Agent 回答的可理解度、内容合理性评估等。

3) 多轮对话与多 Agent 协同质量评价

- 对多轮对话或分步任务执行的场景，应考察上下文衔接度、信息遗失率等指标，衡量 Agent 在持续交互中的表现；
- 若存在多个 Agent 协同工作，可建立协作效率指标，如多 Agent 间任务切换的错误率、冗余度（同样任务是否重复分配给多个 Agent）等。

4) 动态策略迭代与 A/B 实验

- 支持在运行中进行策略或模型版本的 A/B 测试或灰度发布，并可对比两种策略在成功率、时延、用户反馈等方面的差异；
- 通过持续收集线上的用户反馈、日志信息以及外部业务指标，定期自动生成质量评估报告，为策略迭代提供定量依据。

6.1.4 安全合规

1) 敏感操作与高危调用审计

- 应识别 Agent 执行的系统命令、修改配置、访问私有数据或外部付费 API 等高危操作，并进行重点监控与审计；
- 对审计记录进行长期留存、加密存储，并可对接企业内部的安全信息与事件管理类平台。

2) 数据隐私与合规处理

- 对输入与输出中可能包含的个人敏感信息、商业机密等内容，应进行字段脱敏或安全隔离，并遵照相应法律法规与行业标准；
- 应明确数据生命周期管理策略，包括日志留存时长、销毁策略、访问权限控制与数据加密等措施，防止非法泄露。

3) 异常检测与风险防控

- 应具备对异常行为的自动检测能力，如频繁错误调用、可疑的高并发访问、随机的非常规指令输入等，并在触发规则后及时采取阻断或降级措施；
- 支持攻击防护（如 SQL 注入、Prompt 注入）和流量监测，应在 Agent 层或网关层设置相应的策略和限流方案，保护系统免受恶意攻击。

4) 合规审计与可解释性融合

- 应在安全合规审计过程中，能够查看 Agent 决策的关键证据（如引用到的知识库片段、外部接口调用结果）以判断其合理性；
- 对于可能触发合规风险的特殊场景（如金融、医疗），应提供更严格的审计与解释机制，确保输出内容符合相关监管要求。

6.3 关键能力要求（继续补充）

6.2.1 多 Agent 协作场景的交付需求

- 评估是否存在多个 Agent 之间的消息传递、工具/接口调用及信息共享；
- 对多 Agent 间可能发生的协作冲突、任务竞争/抢占、上下文不一致等情况进行预判，并明确需要采集与监控的指标和事件。

6.2.2 可解释性与决策过程

- 为确保智能体行为的透明性，须在设计阶段就考虑可解释性要求。智能体需要能够清晰展示其决策背后的推理过程和决策依据，特别是在涉及复杂任务或多 Agent 协作时。
- 在关键决策节点，智能体应能记录其决策的依据、置信度以及选择理由，并能够提供给审计人员、开发者或者最终用户进行回溯分析。

参 考 文 献

[1]

仅限CCSA TC1 WG5标准起草组内使用 DO NOT COPY