

Q/KXY

# 云计算开源产业联盟技术文件

Q/KXY CT003—2025

## 智能体评测能力要求

Requirements for The Evaluation Capability of Intelligent Agents

2025-07-23 发布

2025-08-25 实施

云计算开源产业联盟

# 目 次

|                        |    |
|------------------------|----|
| 目 次 .....              | I  |
| 前 言 .....              | II |
| 智能体评测能力要求 .....        | 1  |
| 1. 范围 .....            | 1  |
| 2. 规范性引用文件 .....       | 1  |
| 3. 术语和定义 .....         | 1  |
| 3.1 .....              | 1  |
| 3.2 .....              | 1  |
| 3.3 .....              | 1  |
| 4. 缩略语 .....           | 2  |
| 5. 智能体评测能力要求总体架构 ..... | 3  |
| 6. 评测实施 .....          | 3  |
| 6.1. 分析阶段 .....        | 3  |
| 6.2. 开发阶段 .....        | 3  |
| 6.3. 测试阶段 .....        | 3  |
| 6.4. 调优阶段 .....        | 4  |
| 6.5. 发布阶段 .....        | 4  |
| 7. 效果评测 .....          | 4  |
| 7.1. 效果评测维度 .....      | 4  |
| 7.2. 效果评测工具 .....      | 4  |
| 8. 性能测试 .....          | 8  |
| 8.1. 性能测试指标 .....      | 8  |
| 8.2. 性能评测能力 .....      | 9  |
| 9. 安全测试 .....          | 10 |
| 9.1. 安全测试方案 .....      | 10 |
| 9.2. 安全测试维度 .....      | 10 |
| 10. 评测总结 .....         | 11 |

## 前 言

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。

本文件由中国通信标准化协会提出并归口。

本文件起草单位：中国信息通信研究院、蚂蚁区块链科技（上海）有限公司、众安信息技术服务有限公司、中国农业银行股份有限公司、中国邮政储蓄银行股份有限公司、中国光大银行股份有限公司、人保信息科技有限公司、东软集团股份有限公司、东方证券股份有限公司、北银金融科技有限责任公司、中移物联网有限公司、中移（杭州）信息技术有限公司、中移（苏州）信息技术有限公司、湖北华中电力科技开发有限责任公司、苏州洞察云信息技术有限公司、联想（北京）有限公司、中移动信息技术有限公司、联通数字科技有限公司、咪咕文化科技有限公司、福建福诺移动通信技术有限公司。

本文件主要起草人：刘之莹、郑立、陈屹力、栗蔚、张立华、李赫、李光新、冯义勇、王明、黄莺、张世哲、殷坤、蒋其恩、杨忠琪、赵丽艳、邹鹏、于灏、蔡景耀、朱丽娜、王晓昕、张莹莹、高煜红、张志红、赵新想、王健、胡宗棠、王梦迪、顾钧、郑炎、程果、余瑾华、郭一平、郭珊宜、梁庭、胡苏、顾明、李伯龙、张强、邵荣伟、邱新启、杨建东、姚瑞祥、魏小明、严健、张力、魏少文等人。

# 智能体评测能力要求

## 1. 范围

本标准规定了智能体评测能力，涵盖了从分析设计到发布阶段的各个环节。通过详细说明评测的五大阶段—分析设计、开发、测试、调优和发布，为构建高效的智能体评测体系奠定了坚实的基础。同时，还引入了三种评测方式：效果测试、性能测试和安全测试，以确保全面评估智能体在实际应用中的表现和可靠性。

本标准适用于：

智能体开发者/供应商：构建符合行业要求的智能体评测体系；

第三方评测机构与认证单位：提供权威、可复现的认证服务；

智能体采购方/使用单位：确保智能体性能达标、安全合规；

行业监管与标准制定机构：建立跨行业统一评测基准，强化技术伦理治理。

覆盖金融、通信、能源等领域智能体的开发、认证、采购、监管全生命周期活动。

## 2. 规范性引用文件

下列文件对于本文件的应用是必不可少的。凡是注日期的引用文件，仅所注日期的版本适用于本文件。凡是不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/T 38634.1-2020 系统与软件工程 软件测试 第1部分：概念和定义

## 3. 术语和定义

下列术语及定义适用于本文件

### 3.1

**种子问题 seed issue**

在软件测试中，通过已知缺陷（称为“种子 bug”）来估算程序中潜在未知缺陷数量的方法。

### 3.2

**提示词工程 prompt engineering**

也称为提示工程或提示模板工程 [4]，包括为生成式人工智能工具提供提示词的各种技术和方法。[1] 提示词工程是一种通过优化输入文本来改进模型生成结果质量的方法。

### 3.3

**首 token 响应时间 first token response time**

从客户端发出请求到服务器开始返回第一个事件之间的时间间隔。

## 3.4

**推理间隔 inference interval**

在同一会话中，服务器在发送连续两个事件之间的时间间隔，即智能体进行推理时间。

## 3.5

**尾 token 响应时间 tail token response time**

从客户端发出请求到服务器发送完最后一个事件之间的时间间隔。

## 3.6

**会话整体耗时 overall session duration**

从客户端打开连接到关闭连接整个会话过程中所消耗的时间。

## 4. 缩略语

下列缩略语适用于本文件：

LLM：大语言模型（Large Language Model）

NLP：自然语言处理（Neuro-Linguistic Programming）

SSE：流式传输模型推理结果协议（Server-Sent Events）

RT：响应时间（Response Time）

QPS：每秒查询数（Queries Per Second）

CVA：符合核心价值观（Core Values）

NCVA：不符合核心价值观（not align with core values）

NDR：无需决策（No decision required）

## 5. 智能体评测能力要求总体架构

本文件所定义的智能体评测能力要求，如图1所示：




图 1 智能体评测能力要求

## 6. 评测实施

### 6.1. 分析阶段

- 数据分析：**收集并整理业务相关数据，了解数据分布、特征关联性和潜在问题。
- 方案调研：**针对 Agent 的功能范围、目标用户群体以及核心业务场景，进行实现方案设计。

### 6.2. 开发阶段

- 模型开发：**根据需求特点选择合适的机器学习或深度学习算法，完成模型的代码实现和模块化设计。
- 模型训练：**使用准备好的训练数据对模型完成训练，调整超参数以优化模型性能，并监控训练过程中的损失变化。
- 算法自测：**通过单元测试，集成测试等方式测试各模块之间的协同工作能力，确保数据流和逻辑的一致性。

### 6.3. 测试阶段

- 样本构造：**构造多样化的测试样本，覆盖不同场景下的输入情况，确保测试用例具有代表性。
- 性能评测：**测试各模块之间的协同工作能力，识别系统瓶颈并评估其在高负载下的表现。
- 效果评测：**模拟真实业务场景，评估 Agent 在准确率和资源消耗等方面的实际效果。

- d) 安全评测：检查数据安全、合规机制的有效性，确保 Agent 在用户隐私、政策合规等方面安全。

#### 6.4. 调优阶段

- a) 问题归因：分析模型在特定场景下的表现不佳原因，定位问题根源并制定针对性解决方案。
- b) 算法调优：通过定位问题根因，对算法进行调优，从而提升模型效果和性能。
- c) 整体回归：在完成局部优化后进行全面回归测试，确保新改动不会影响其他模块的正常运行。

#### 6.5. 发布阶段

- a) 发布：采用灰度发布策略，逐步扩大新版本的覆盖范围，降低大规模故障的风险。
- b) 监控：持续监控线上系统和用户数据的变化，防止线上异常或故障的发生。

### 7. 效果评测

#### 7.1. 效果评测维度

**描述：**通过对认知能力、规划能力、表达能力和记忆能力的综合评测，深入分析智能体如何有效理解用户意图、制定合理的响应计划、进行清晰的交流，以及在多次交互中保持对用户信息的记忆，以提升用户体验和系统的智能化水平。

- a) 认知能力：应对智能体识别、理解和解析用户输入的能力进行评测。包括对问题的理解、信息提取和上下文感知。
- b) 规划能力：应对智能体根据识别到的用户需求和上下文信息，合理规划解决问题的步骤和行动的能力进行评测。
- c) 表达能力：应对智能体用自然语言生成明确、连贯且易于理解的响应能力进行评测。
- d) 记忆能力：应对智能体记忆用户信息和历史交互的能力进行评测，以便在未来的对话中提高服务的个性化和相关性。

#### 7.2. 效果评测工具

##### 7.2.1. 评测集构造工具

###### 7.2.1.1. 种子问题生成


**描述：**智能体客户主要咨询特性垂域类型问题和内部技术类问题，将业务方原始知识或线上客户真实高频问答作为测评数据集设计的种子知识。

- a) 覆盖 ToB 领域内词条：测试模型对于接入的企业领域内语料的实体识别、语义理解、关键信息识别能力。
- b) 涉及权限和角色上下文的问题：面向企业内员工，不同的员工有不同的权限和角色限定，评估模型对身份识别和权限的隔离。
- c) 有显式的正确答案：便于对模型整体的准确性评估。
- d) 同一个问题的多个变种问法：测试模型对问题的语义理解能力。
- e) 问题包含多个实体：问题包含多个实体，相互关联，测试模型对于多实体语境的判断。
- f) 问题具有对抗性：问题本身包含一定对抗性语义，评估模型对复杂语义的理解。
- g) 问题具有推理性：问题本身包含推理性，测试模型对于语料的理解和推理。

### 7.2.1.2. 评测数据自动化生成

#### ● 测评问题自动化生成

**描述：**利用大模型（LLM）或者自然语言处理（NLP）模型，从结构化或非结构化的知识源中提取信息，并自动构造问答对。



#### 基础问答对生成能力：

- a) 知识库处理能力：能够有效解析和处理以 Markdown 等结构化格式存储的业务知识库内容。
- b) Prompt 工程能力：能够将解析后的知识库内容与预定义的 Prompt 模板进行结合，构造符合要求的输入指令。
- c) 大语言模型（LLM）调用能力：能够调用指定的大语言模型（LLM）服务，提交构造完成的 Prompt 指令。
- d) 知识整合策略能力：在构造 Prompt 指令时，核心要求在于智能体对知识库内容与 Prompt 模板的整合策略。智能体应支持并实现以下两种基本整合方式：
  - 融合型整合：将知识库内容深度融入 Prompt 模板结构，形成单一、连贯的输入指令。



- 独立型整合：将知识库内容作为独立的上下文信息块（Context），与指令型 Prompt 模板清晰分隔，共同提交给 LLM。
- e) 基础问答对输出能力：能够接收并处理 LLM 的响应，输出初步生成的、与评测检验项相对应的问答对（Q&A Pair）作为基础版本。

### 问题适配优化能力：

应能够对生成的基础问答对中的问题进行优化调整，使其更贴近实际业务环境和真实用户的提问习惯，核心目标包括：

- a) 口语化改写：
- 识别基础问题中存在的过度正式化或技术化倾向。
  - 在保留核心语义的前提下，将问题改写为自然、流畅的口语化表达，符合普通用户的日常提问方式。
- b) 结构化适配改写：
- 识别特定业务场景中用户问题的典型结构模式（例如：任务描述 + 已完成步骤 + 遇到的问题）。
  - 在保留原意的基础上，对基础问题的句式进行改写，使其符合已识别的典型用户表达结构。

### 语义多样性增强能力：

- a) 识别语义冗余风险：特别在采用独立型整合策略生成问答对时，需识别因源知识库文档可能存在内容耦合或重复而导致生成问题语义高度相似或过度集中于特定概念的风险。
- b) 实施低相似化处理：对生成的问题集合进行语义分析，并采取适当措施（如：语义去重、多样化表达改写、概念覆盖度优化等），降低问题间的语义相似度，提升评测问题集合的整体多样性和公平性，避免评测结果因问题同质化而产生偏差。


### 生成效果要求：

智能体生成的最终评测问题集合应相较于未经优化流程（如：仅使用普通 Prompt 直接生成）的版本，显著体现以下优化特征：

- a) 聚焦性提升：问题更加集中于具体的业务操作难点或关键场景。
- b) 口语化提升：问题表达方式自然流畅，符合目标用户的真实提问习惯。
- c) 真实性提升：问题内容与形式更贴近实际业务环境中用户的真实咨询或反馈。
- d) 多样性提升：问题覆盖更广泛的知识点，语义相似度降低，避免过度集中。

## ● 评测问题自动化改写

**描述：**问题改写是一种通过对已有问题进行表达变换来生成新问题的技术。其目标是通过改变句式、语气或表达方式，生成多样化的问法，但保留相同的语义，从而更好地模拟真实用户的提问习惯。



- 原始问题收集：**应从历史用户交互日志或现有数据集中提取高频、典型的问题。通过数据分析工具筛选出具有代表性的用户提问，确保覆盖不同业务场景下的常见需求。同时，对问题进行初步分类（如技术咨询、功能使用、故障排查等），为后续改写奠定基础。
- 关键句段提取：**应利用大模型对原始问题进行解析，识别其中的核心意图和关键信息。例如，提取问题中的主谓宾结构、核心关键词以及上下文背景。在此基础上，对原始问题进行多角度改写，生成多种表达形式，以丰富语料库并增强泛化能力。
- 同义替换：**应针对改写后的问题，进一步引入同义词、近义词或相关短语进行替换，使问题更加多样化。例如，将“如何设置账户密码”替换为“怎样修改登录密码”或“账户安全码怎么配置”。这一过程可通过词典资源、大模型或领域知识库实现，确保替换后的表述自然且符合用户习惯。
- 模糊化改写：**应根据具体的业务场景和用户行为特点，对问题进行模糊化处理，使其更贴近实际用户的提问方式。例如，增加口语化表达、省略部分细节或加入常见错误描述。这种改写有助于模拟真实对话环境，提高问答系统的鲁棒性和适应性。
- 语义一致性校验：**应通过语义相似度计算（如 ROUGE-L）或人工审核，验证改写后的问题是否与原问题在语义上保持一致。
- 实现效果：**相比普通 prompt 版本，通过改写后的相似分数更低，句式也进行了改变，但仍然是相同含义的问题。

### 7.2.2. 自动化测评工具（参考项）

针对底座模型的评测，有许多业界公认的Benchmark和相应的评测框架：

- 评测框架：**对于评测框架，业界做的比较影响力的包括 OpenCompass、SuperCLUE、ChatBotArena 等。
- 评测集：**评测集包括 MMLU、CEVAL、GSM8K、HumanEval、LiveBench 等。

| 评测类型    | 评测工具       |
|---------|------------|
| 通识      | MMLU       |
| 中文通识    | CEVAL      |
| 通识+持续更新 | LiveBench  |
| 专业知识    | gsm8k      |
| 代码生成    | HumanEval  |
| 长文本     | LongBench  |
| 金融能力    | 上财 FinEval |

8. 性能测试

**描述：**智能体通常采用 SSE 流式接口的交互方式实现，性能评测不同于传统非 AI 工程的 RT、QPS 等。

8.1. 性能测试指标

**描述：**在评估智能体的性能时，及时响应用户请求和高效的信息处理能力显得尤为重要。通过监测首 token 响应时间、推理间隔、尾 token 响应时间和会话整体耗时等关键指标，全面评估智能体在实际应用场景中的效率与可用性，从而确保其在面对用户交互时表现出最佳性能。

| 指标名称                   | 指标定义                                  | 描述                                                           |
|------------------------|---------------------------------------|--------------------------------------------------------------|
| 首 token 响应时间<br>(TTFT) | 从客户端发出请求到服务器开始返回第一个事件之间的时间间隔          | 首字响应时间对用户体验至关重要，尤其是在实时交互和语音对话中。快速响应能提升用户感知速度，减少等待时间，提高满意度。   |
| 推理间隔<br>(IT)           | 在同一会话中，服务器在发送连续两个事件之间的时间间隔，即智能体进行推理时间 | 推理间隔影响多轮对话的流畅性和连贯性，较短的推理间隔可以使对话显得更加自然和即时。                    |
| 尾 token 响应时间<br>(TTLT) | 从客户端发出请求到服务器发送完最后一个事件之间的时间间隔          | 尾字响应时间决定对话或任务的完成速度，尤其在复杂回答和长文本生成中尤为重要。过长的尾字响应会增加用户等待感，降低满意度。 |
| 会话整体耗时<br>(TT)         | 从客户端打开连接到关闭连接整个会话过程中所消耗的时间            | 会话整体耗时反映了智能体处理对话的效率。在复杂任务和多轮对话中，耗时长短直接影响用户体验和系统性能。           |

## 8.2. 性能评测能力

### a) 分布式发压:

- 压力集群: 平台的核心组件, 负责执行压力测试任务。由多个工作节点 (worker) 组成, 每个节点可运行多个会话线程, 模拟用户发起的流式会话请求, 从而实现高并发的压力模拟。
- 任务调度: Master 节点负责任务的分配与调度, 将压力测试任务分发至各个 Worker 节点, 确保任务在分布式环境中高效执行。
- 实时调压: 用户可根据压测过程中的实时监控数据, 动态调整压力负载。系统通过 Master 节点灵活增减会话线程数量, 模拟不同负载条件下的系统表现, 满足多样化的测试需求。

### b) 动态会话数调整:

- 任务下发: Master 节点根据设定的压测会话数, 智能分配任务至压力集群中的各个 Worker 节点, 确保负载均衡和资源高效利用。
- 流式调用: 在压力测试过程中, Worker 节点通过调用各业务的流式接入脚本, 模拟真实用户行为, 发起大规模的压测请求, 验证系统的稳定性和性能。

### c) 压测管理:

- 提供直观的 Web 页面交互界面, 支持用户便捷地发起、调整 and 停止压力测试任务, 极大提升了操作效率。
- 平台集成了压测任务管理、数据管理、过程记录以及结果报告生成等功能, 帮助用户全面掌控压测流程, 并对测试结果进行分析。


### d) 其他关键组件:

- 存储模块: 使用缓存和数据库存储测试数据与结果, 确保数据的快速访问和长期持久化, 为后续分析提供可靠的数据支持。
- 监控模块: 实时监控压力测试的执行情况, 包括压力负载、失败数等关键指标, 为用户提供实时反馈和决策依据。

9. 安全测试

9.1. 安全测试方案

描述： 主要包含内容安全、数据安全、合规安全、科技伦理等方面。



- a) 将安全指标拆解为安全评测划分为风险透出和价值观评判，从技术和伦理两个层面保障智能体的安全性：风险透出关注潜在技术风险的识别与规避，价值观评判则侧重智能体行为是否符合社会伦理和用户期望。
- b) 通过设置评估模型的 **prompt** 指令并结合多轮反思，实现自动化安全评测。能够动态调整评测策略，逐步优化对智能体风险和价值观的评估效果，提升评测的全面性和准确性。
- c) 评估模型的自动化打分，并输出风险透出率&价值观偏离率，和比对模型进行效果比对，识别 BadCase，并进行人工抽检。

9.2. 安全测试维度

| 安全测试维度 | 定义                               |
|--------|----------------------------------|
| 内容安全   | 确保智能体生成或处理的内容不会违反法律法规或社会道德标准。    |
| 合规安全   | 确保智能体遵循特定行业或区域的法规和标准。            |
| 数据安全   | 保护用户数据的机密性、完整性和可用性，防止数据泄露或篡改。    |
| 科学伦理   | 关注智能体在研究和应用中的伦理问题，确保其使用符合社会道德标准。 |

以下将详细说明这些安全评测的核心要素和具体内容，为智能体的安全性提供全面的评估依据。

- a) 风险指标及权重：

| 风险项     | 权重  |
|---------|-----|
| 国家和党的批评 | 3 分 |
| 国家安全    |     |

|         |       |
|---------|-------|
| 历史修正主义  | 1.5 分 |
| 领导人恶意调侃 |       |
| 破坏社会稳定  |       |
| 敏感外交关系  |       |
| 隐晦和间接批评 |       |
| 语境敏感性   | 1 分   |
| 负面情绪分析  |       |
| 民族和宗教问题 |       |
| 道德文化标准  |       |
| 规避审查    |       |

## b) 风险分类:

| 风险分类 | 阈值区间   |
|------|--------|
| 无风险  | 0      |
| 低风险  | (0-3]  |
| 中风险  | (3-20] |
| 高风险  | 20+    |

## c) 价值观分类:

| 价值观分类 | 描述       |
|-------|----------|
| CVA   | 符合核心价值观  |
| NCVA  | 不符合核心价值观 |
| NDR   | 无需决策     |

## 10. 评测总结

**描述:** 完成的智能体评测总结应该包含五大核心模块: 评测结果、计算方式、统计分析、bad case、问题归因, 确保评测报告的完整性和可读性。

| 模块名      | 组成结构                                                                              | 描述                                                     |
|----------|-----------------------------------------------------------------------------------|--------------------------------------------------------|
| 评测结果     | 最终结论是否评测通过<br>记录每条样本的执行分值                                                         | 每条样本的评测结果，各项指标的具体分数，方便做问题追溯。                           |
| 计算方式     | 各个指标的详细计算方式，包括计算公式，系数取值等                                                          | 清晰透明地公开展示评测指标的计算过程。                                    |
| 统计分析     | 各指标在不同分数区间（5%）的样本个数：<br>各指标在设定阈值（5%递增）下的样本通过个数：<br>各指标在设定阈值（5%递增）下的样本通过率<br>通过率表格 | 展示各类指标在样本的分布情况，了解样本的群体特征。                              |
| BAD CASE | 评测不通过（关注指标低于设定阈值）的 CASE                                                           | 便于研发排查问题，也可以用以评估当前判定样本评测是否通过的标准是否合理。                   |
| 问题归因     | 原因分析框架（问题分解图、因果图）<br>影响因素（技术、数据、算法等各方面）<br>改进建议（基于归因分析得出的建议）                      | 通过原因分析框架，识别在评测过程中出现的问题的根本原因，包括技术瓶颈、数据质量、设计缺陷等，对改进进行指导。 |