



中华人民共和国通信行业标准

XX/T s—XXXX

AI 云智算运营能力分级要求 第 2 部分：模型运营

Classification Requirements for AI Cloud Intelligent Computing Operation
Capability Part 2: Model Operation

[点击此处添加与国际标准一致性程度的标识]

(征求意见稿)

2025 年 2 月 20 日

XXXX - - XX 发布

XXXX - XX - 实施

中华人民共和国工业和信息化部 发布

目次

前 言 II

AI 云智算运营能力分级要求 第2部分：模型运营 1

1. 范围 1

2. 规范性引用文件 1

3. 术语和定义 1

3.1. 1

3.2. 1

3.3. 1

4. 缩略语 2

5. 智算模型运营能力分级要求总体架构 2

6. 智算模型运营能力分级规则 2

6.1. 分级概述..... 2

6.2. 分级规则..... 2

7. 模型开发和训练 3

7.1. 模型开发..... 3

7.2. 训练优化..... 3

7.3. 分布式训练..... 3

7.4. 超参数调优..... 4

7.5. 过程监控与断点续训..... 4

8. 模型推理和部署 5

8.1. 模型推理..... 5

8.2. 模型压缩与量化..... 5

8.3. 推理加速..... 6

8.4. 容器化与微服务架构..... 6

8.5. 多环境部署支持..... 6

9. 模型调用与集成 7

9.1. 模型调用..... 7

9.2. 第三方模型集成..... 7

10. 模型管理 7

11. 模型资产化与应用 8

11.1. 模型价值评估..... 8

11.2. 模型仓库..... 8

11.3. 审计管理..... 9

前 言

本文件按照GB/T 1.1—2020《》给出的规则起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别这些专利的责任。

本文件由中国通信标准化协会提出并归口。

本文件起草单位：中国信息通信研究院、xxx

本文件主要起草人：刘之莹、xxx、xxx等人

AI 云智算运营能力分级要求 第 2 部分：模型运营

1. 范围

本标准综合衡量模型运营服务成熟度，覆盖模型开发和训练、模型推理和部署、模型调用与集成、模型管理及模型资产化与应用 5 方面智算集群模型运营能力要求。

本标准适用于行业内或区域内提供模型开放能力/解决方案相关服务或工具的企业，包括云服务商、AI 技术提供商、模型运营需求方等，对运营方的模型运营能力进行规范。

2. 规范性引用文件

下列文件对于本文件的应用是必不可少的。凡是注日期的引用文件，仅所注日期的版本适用于本文件。凡是不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

算力网络通用框架与架构、智算工程平台能力要求、人工智能算力网络技术规范等。

3. 术语和定义

下列术语及定义适用于本文件

3.1

智算云 Intelligent computing cloud

以 AI 算力为核心引擎，聚焦算力资源全面高效调度资源与运维能力。

3.2

算力运营 computing power operation

对智算资源进行高效调度、监控和运营管理，以提升资源利用效率。

3.3

算力网络 Computing Power Network

通过软件定义网络（SDN）与算力感知路由协议，实现跨地域、跨服务商的算力资源按需调度与计费结算。

4. 缩略语

下列缩略语适用于本文件：

GPU：图形处理器（Graphics Processing Unit）

NPU：神经网络处理单元（Neural Processing Unit）

IHN：智能高性能网络（Intelligent High-Performance Network）

MFU：模型算力利用率（Model FLOPs Utilization）

5. 智算模型运营能力分级要求总体架构

本文件所定义的智算模型运营能力分级要求架构，如图1所示：



图 1 智算模型运营能力分级要求架构

6. 智算模型运营能力分级规则

6.1. 分级概述

智算模型运营能力分级要求，共分为3个级别，每个级别中按照不同程度说明。各级别对应的具体能力要求见第7-11章。各级别技术要求描述如下：

- 基础级：能够基本实现功能要求；
- 增强级：在基础级能力上，具备较高级的功能实现；
- 先进级：在增强级能力上，具备行业内领先的功能实现。

6.2. 分级规则

智算模型运营能力分级要求，能力要求项分为1级、2级、3级。

满足90%的1级能力项，即可认为达到基础级要求；
满足90%的1级、2级能力项，即可认为达到增强级要求；
满足90%的1-3级能力项，即可认为达到先进级要求。
可选项供参考，不作为必须满足项。

7. 模型开发和训练

7.1. 模型开发

1 级：

- 1) 应提供开发机服务，用于在线编译、调试代码和模型开发。
- 2) 支持分布式块存储服务，用于模型数据的存储。

2 级：

- 1) 应支持远程登录到开发机上，并在开发机上执行命令；
- 2) 应支持上传与下载文件，支持开发机文件传输；
- 3) 应支持开发机的监控，监控开发机的显卡、CPU、内存资源使用情况；

3 级：

——应提供在线的交互式开发环境，像使用本地环境一样使用远端开发环境，如 JupyterLab、vscode 等，提高开发效率；

7.2. 训练优化

1 级：

- 1) 应提供高效数据预处理服务，包括数据清洗、特征工程、数据并行处理等，减少训练准备时间，提升整体效率；
- 2) 宜集成基础数据增强工具，支持常见的数据扩增方法（如旋转、裁剪、噪声注入等），提升模型泛化能力基础；

2 级：

——应支持使用混合精度训练优化技术，降低显存等资源占用，便于加速计算；

3 级：

- 1) 应提供实时训练监控工具，跟踪训练性能，及时发现瓶颈问题，支持异常波动自动告警；
- 2) 宜支持数据流水线优化机制，包括数据加载和缓存机制优化，减少 I/O 等待时间，保障训练数据供应的连续性。

7.3. 分布式训练

1 级：

——应支持主流分布式训练框架，实现数据并行、模型并行、混合同并行等策略。

2 级：

- 1) 应能制定详细的分布式训练 SLA，明确训练任务的服务质量和性能指标，如训练时间、资源利用率等；
- 2) 应支持细粒度资源监控，实时采集 GPU 显存占用率等关键指标；
- 3) 应能实施全面的服务质量管理，包括定期的性能评估。

3 级：

- 1) 应建立多层次的监控体系，确保对分布式训练过程的实时了解和掌控，包括对训练数据的分布、模型参数的更新等进行监控；
- 2) 应持续对分布式训练进行年度审核或者周期审核，包括：训练任务的完成情况、资源使用效率、模型性能等；
- 3) 应能建立过程管理体系，确保分布式训练的持续优化和改进，如通过自动化工具进行训练任务的调度和管理；

7.4. 超参数调优

1 级：

——应具备基本的手动调整超参数的能力，根据训练结果对超参数进行简单的优化。

2 级：

- 1) 应能制定详细的超参数调优策略，明确超参数的范围和调整规则；
- 2) 应支持使用自动化工具进行超参数的搜索和优化，提高调优效率。

3 级：

- 1) 应建立多层次的超参数调优体系，包括对模型结构、训练算法等进行综合调优，确保模型的高性能和泛化能力；
- 2) 应持续对超参数调优过程进行监控和评估，包括对调优结果的验证和对调优过程的优化；
- 3) 应确保超参数调优的持续优化和改进，如通过贝叶斯优化、遗传算法等高级方法进行超参数优化；
- 4) 宜提供可视化调优工具，展示调优过程并做出决策；
- 5) 宜支持超参数历史数据分析，通过分析提供调优建议，避免重复搜索低效区域。

7.5. 过程监控与断点续训

1 级：

——应建立基本的过程监控机制，能够实时监测模型训练任务的运行状态，及时发现训练中断风险。

2 级：

- 1) 应建立多维度细粒度的过程监控体系，包括硬件资源层（如计算/存储/网络资源利用率）、算法层（如 loss 曲线/梯度变化）和结果层（如验证集准确率）；
- 2) 应具备较强的中断恢复能力，能够在中断事件发生后，迅速启动恢复计划，确保关键业务在规定时间内恢复运行。
- 3) 应提供实时训练监控工具，跟踪训练过程中资源使用情况，及时发现异常。
- 4) 宜具备自动化报警机制，设置训练过程关键指标，包括 GPU 利用率、内存占用等阈值，自动触发报警。

3 级:

- 1) 应建立多层次的过程监控体系, 包括对业务流程、IT 系统、人员操作等多方面的实时监控, 确保对业务运行的全方位掌控。
- 2) 应持续对中断恢复过程进行优化和改进, 定期对恢复计划进行演练和评估, 提高恢复效率和成功率。
- 3) 应能够对业务流程进行持续优化, 减少中断事件的发生概率, 提升业务的稳定性和连续性;
- 4) 宜具备自动恢复功能, 在分布式训练中, 支持节点故障自动检测和任务回复, 保障训练任务在节点故障后继续运行;
- 5) 宜具备应用日志管理与分析能力, 提供日志管理工具, 用于问题排查与训练分析;
- 6) 宜具备故障检测、故障定位、故障预测、故障隔离能力, 用于快速故障处理;
- 7) 可提供训练任务优先级管理服务, 确保高优先级任务在资源紧张时能够优先运行和恢复。

8. 模型推理和部署

8.1. 模型推理

1 级:

——应提供模型市场, 支持丰富的模型类型, 预置主流模型。

2 级:

- 1) 应提供开箱即用的推理 API 服务, 支持在线体验;
- 2) 宜支持用户自行部署模型到专属实例, 并以私有 API 提供推理服务。

3 级:

——应支持查看模型服务的调用统计信息, 支持按 token 计量计费。

8.2. 模型压缩与量化

1 级:

——应建立基本的模型压缩与量化机制, 确保模型能够在资源受限的环境中运行。

2 级:

- 1) 应能制定详细的模型压缩与量化策略, 明确压缩和量化的具体方法和目标;
- 2) 应支持模型剪枝、参数量化;
- 3) 应建立定期评估机制, 对压缩和量化后的模型性能进行评估, 确保模型在压缩和量化后仍能满足性能要求;
- 4) 应开始对模型压缩与量化过程进行一定程度的监控和优化, 能实施全面的模型质量管理, 包括定期的性能评估。

3 级:

- 1) 应对模型压缩与量化过程进行深度审计和监控, 确保其严格遵守模型性能和资源利用要求;
- 2) 应支持模型剪枝, 通过移除冗余权重, 减少模型参数量和计算复杂度, 提升推理效率;
- 3) 应支持压缩模型部署在云端、边缘侧、终端上高效运行;
- 4) 宜提供模型量化性能评估工具, 分析量化后的模型精度、训练速度和资源消耗;
- 5) 可支持硬件感知量化优化, 根据不同硬件类型与特性, 优化量化策略。

8.3. 推理加速

1 级：

- 1) 应建立基本的推理加速机制，确保模型能够快速响应推理请求；
- 2) 宜支持模型剪枝与量化，减少模型参数量和计算复杂度，提升推理性能。

2 级：

- 1) 应支持包括 GPU、TPU、NPU 的等硬件的加速支持，提升模型推理速度；
- 2) 应支持分布式推理和负载均衡架构，将推理任务拆分到多个节点并行处理；
- 3) 应支持边缘侧部署，减少数据传输延迟，提升实时推理性能；
- 4) 应能制定详细的推理加速策略，明确推理加速的具体方法和目标；
- 5) 应建立定期评估机制，对推理加速后的模型性能进行评估，确保模型在加速后仍能满足性能要求。

3 级：

- 1) 应支持如 TensorRT、ONNX Runtime 等高效推理引擎，优化推理性能；
- 2) 宜支持批处理等加速技术，优化推理性能；
- 3) 应支持自动扩缩容机制，根据推理请求量动态调整计算资源；
- 4) 宜提供实时推理性能监控工具。

8.4. 容器化与微服务架构

1 级：

/

2 级：

- 1) 应提供基于 Docker 的模型容器化支持，将模型及依赖环境轻量化，实现快速部署和运行；
- 2) 宜支持 Kubernetes 编排管理，实现模型容器自动化部署、扩缩容和复杂均衡。

3 级：

- 应提供模型服务微服务架构设计与拆分，包括数据预处理、推理等，提升服务灵活性。

8.5. 多环境部署支持

1 级：

- 应支持模型在云端、边缘端、本地、设备端中无缝部署和运行。

2 级：

- 1) 应提供代码工具，自动化配置多环境下的资源部署，提升部署效率；
- 1) 应支持跨地域/多副本部署，保障服务高可用性；
- 2) 宜支持不同环境下的模型迁移，确保开发、测试和生产环境的一致性。

3 级：

- 宜提供多环境安全策略，如网络隔离、访问控制、数据加密等，确保模型在多环境下的安全性与合规性。

9. 模型调用与集成

9.1. 模型调用

1 级：

——应提供统一的 API 网关，集中管理模型调用接口，提升调用效率和稳定性。

2 级：

- 1) 应支持调用权限控制，通过如基于角色的访问控制机制，管理不同用户或系统对模型调用的访问权限，确保安全性与合规性；
- 2) 应具备模型调用限流和熔断机制，防止因高并发或异常请求导致的服务崩溃；
- 3) 宜支持模型调用性能优化，通过优化模型推理性能，降低调用延迟。

3 级：

——应支持模型调用安全防护机制，引入身份验证、数据加密等机制，确保模型调用安全性和数据隐私。

9.2. 第三方模型集成

1 级：

/

2 级：

- 1) 应支持第三方集成模型的全面兼容性测试；
- 2) 应具备服务编排框架，支持第三方模型服务的任务管理。

3 级：

- 1) 应提供数据格式转换工具，支持第三方模型的数据格式与现有系统兼容；
- 2) 应具备可视化编排工具，可直观设计和调整第三方模型服务的调用流程；
- 3) 应提供自动化集成工具，支持第三方模型的快速集成，包括接口适配、数据转换和测试验证。

10. 模型管理

1 级：

- 1) 应提供模型版本管理工具，确保模型代码、配置和数据的变更可追溯、可回滚；
- 2) 应支持模型的灰度发布策略，逐步推送，降低更新风险；
- 3) 应具备模型退役的评估机制，退役前进行全面性能评估和业务影响分析；
- 4) 应提供模型服务的基础备份功能，并具备针对服务异常的故障告警机制，保障模型服务的稳定性。

2 级：

- 3) 应支持通过 CI/CD 流水线实现模型版本的自动化构建、测试和发布，提升版本发布效率和质量；

- 4) 应支持基于角色的访问控制机制，限制不同用户对模型版本的访问和操作权限，确保版本管理的安全性；
- 5) 应具备数据备份、归档、版本历史记录机制，确保数据可追溯性、知识管理和模型复现的可能性；
- 6) 应支持资源释放与回收，针对硬件和软件资源进行回收，降低成本；
- 7) 应建立容灾演练机制，定期验证恢复流程。

3 级：

- 1) 应支持版本的全生命周期管理，确保每个版本的管理规范化和系统化；
- 2) 应构建自适应容灾系统，实时自动更新备份，实时监控环境异常并自动切换灾备节点。

11. 模型资产化与应用

11.1. 模型价值评估

1 级：

——应定义模型价值评估维度（如准确率、业务 ROI）。

2 级：

——应建立定量评估体系，结合 A/B 测试与业务指标（如转化率、成本节省）。

3 级：

- 1) 应构建动态价值评估模型，关联市场反馈与长期收益预测；
- 2) 宜具备模型业务价值评估模型，提供基于业务目标的模型价值评估框架，量化模型对业务指标的贡献；
- 3) 宜具备从模型精度、推理速度、资源消耗等维度的模型性能指标评估，确保满足业务需求。

11.2. 模型仓库

1 级：

- 1) 应提供统一的模型库管理平台，支持模型的分类、存储和版本管理，提升模型管理的规范性；
- 2) 宜具备模型版本管理功能。
- 3) 应支持模型的上架、展示、交易和下载；
- 4) 应提供模型基础参数说明，包含版本、硬件适配、性能表现等核心信息。

2 级：

- 1) 应具备模型关键词检索，按条件筛选排序等功能；
- 2) 应实现模型与算力资源的自动匹配推荐，提供部署配置建议；
- 3) 应建立模型版本管理机制，支持历史版本追溯与更新通知。
- 4) 宜针对模型的性能和应用场景，制定合理定价策略，支持如订阅收费、API 调用收费、定制化收费等。

3 级：

- 1) 应支持智能模型推荐能力，根据用户需求及应用场景等要素自动推荐目标模型；
- 2) 应构建跨平台模型转换工具链，支持主流框架的自动化迁移；

3) 应建立模型准入与审核机制, 包括对入驻模型的来源合法性、知识产权归属、安全性等进行审核。

11.3. 审计管理

1 级:

——应具备模型使用情况记录能力, 包括调用时间、调用者、输入输出结果等, 便于追踪和审计。

2 级:

- 1) 应建立模型数据生命周期管理机制, 包括数据的收集、存储等环节, 确保隐私数据的安全;
- 2) 应支持对模型文件的加密存储和传输, 防止未经授权的访问和使用, 确保模型的安全性;
- 3) 应具备模型自动化审计工具, 支持模型使用情况的追踪和审计。

3 级:

- 1) 应支持加密数据的直接推理, 确保数据在推理过程中的隐私和安全;
 - 2) 应支持模型许可授权管理, 支持按时间、次数或用户范围进行授权, 确保模型的使用符合授权协议。
-