



中华人民共和国通信行业标准

XX/T s—XXXX

AI 云智算运营能力分级要求 第 3 部分：算力运营

Classification Requirements for AI Cloud Intelligent Computing Operation
Capability Part 3: Computing Operations

[点击此处添加与国际标准一致性程度的标识]

(征求意见稿)

2025 年 2 月 20 日

XXXX - - XX 发布

XXXX - XX - 实施

中华人民共和国工业和信息化部 发布

目次

前 言 II

AI 云智算运营能力分级要求 第 3 部分：算力运营 1

1. 范围 1

2. 规范性引用文件 1

3. 术语和定义 1

3.1. 1

3.2. 1

3.3. 1

4. 缩略语 2

5. 智算算力运营能力分级要求总体架构 2

6. 算力资源纳管 2

6.1. 算力并网接入..... 2

6.2. 资源元数据建模..... 2

6.3. 资源拓扑治理..... 3

6.4. 异构资源兼容..... 3

7. 算力编排调度 3

7.1. 算力开通..... 3

7.2. 算力编排..... 4

7.3. 算力调度..... 4

7.4. 弹性扩缩容..... 4

8. 算力资源感知 5

9. 算力运营能力开放 5

前 言

本文件按照GB/T 1.1—2020《》给出的规则起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别这些专利的责任。

本文件由中国通信标准化协会提出并归口。

本文件起草单位：中国信息通信研究院、xxx

本文件主要起草人：刘之莹、xxx、xxx等人

AI 云智算运营能力分级要求 第 3 部分：算力运营

1. 范围

本标准综合衡量算力运营能力成熟度，覆盖算力资源纳管、算力编排调度、算力资源感知及算力运营能力开放 4 方面智算集群算力运营能力要求。

本标准适用于 AI 云智算领域的算力服务提供方、使用方，包括云计算服务商、算力资源管理团队、智能化应用开发企业等，助力其实现算力资源科学化、标准化运营。

2. 规范性引用文件

下列文件对于本文件的应用是必不可少的。凡是注日期的引用文件，仅所注日期的版本适用于本文件。凡是不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

算力网络通用框架与架构、智算工程平台能力要求、人工智能算力网络技术规范等。

3. 术语和定义

下列术语及定义适用于本文件

3.1

智算云 Intelligent computing cloud

以 AI 算力为核心引擎，聚焦算力资源全面高效调度资源与运维能力。

3.2

算力运营 computing power operation

对智算资源进行统一管理、科学调度和高效利用，提升资源运营效率的过程。

3.3

算力网络 Computing Power Network

通过软件定义网络（SDN）与算力感知路由协议，实现跨地域、跨服务商的算力资源按需调度与计费结算。

4. 缩略语

下列缩略语适用于本文件：

GPU：图形处理器（Graphics Processing Unit）

NPU：神经网络处理单元（Neural Processing Unit）

IHN：智能高性能网络（Intelligent High-Performance Network）

MFU：模型算力利用率（Model FLOPs Utilization）

5. 智算算力运营能力分级要求总体架构

本文件所定义的智算算力运营能力分级要求架构，如图1所示：



图 1 智算算力运营能力分级要求架构

6. 算力资源纳管

6.1. 算力并网接入

算力并网接入主要实现底层各类云平台对接，实现算力资源的标准化并网接入，实现算力资源的统一纳管。

- a) 应支持三方云管平台对接，实现三方云管算力资源的纳管；
- b) 应支持三方云原生平台对接，实现三方云原生算力的纳管；
- c) 宜支持三方运营平台对接，实现三方运营平台服务资源的纳管；
- d) 宜支持边缘集群的接入，实现云边资源的统一纳管。

6.2. 资源元数据建模

资源元数据建模主要聚焦资源类型的静态属性定义。解决“资源长什么样”，实现对资源类型的扩展定义，方便对资源进行分级管理及属性管理，从而实现模型标准化。

- a) 应支持资源类型自定义，例如虚拟机、宿主机、裸金属等不同资源类型；
- b) 应根据 GPU、CPU 等计算资源的性能和使用场景，将其划分为不同的等级（如高性能、标准、轻量等），面向不同任务（如实时推理、批量推理等）进行优先匹配；
- c) 应支持资源类型的属性自定义，例如裸金属的 CPU 大小、内存大小、所属机房、所在机柜等；
- d) 宜支持资源类型间关联关系，例如虚拟机与宿主机的运行关系。

6.3. 资源拓扑治理

资源拓扑治理主要对多层资源（包括各种计算、存储、网络以及 PaaS 资源）进行整合管理，解决“资源如何连接”，支持从云服务创建到释放的全生命周期管理。

- a) 应支持计算资源的统一管理，例如虚拟化资源、容器化资源、裸金属资源、智算卡资源等；
- b) 应支持存储资源的统一管理，例如对象存储、文件存储等存储资源管理；
- c) 应支持网络资源统一管理，例如网络、子网、弹性 IP 等资源管理；
- d) 宜支持 PaaS 软件资源的统一管理，例如中间件服务、数据库服务等；
- e) 宜支持资源间关系管理，例如软件服务及容器、软件服务与虚拟机等。

6.4. 异构资源兼容

异构资源兼容主要是对异构 CPU、异构智算卡的兼容性能力，保障算力资源的异构调度能力。

- a) 应支持异构 CPU 资源池的统一纳管；
- b) 应支持对异构智算卡池（英伟达、国产加速卡）的统一纳管；
- c) 宜支持对异构 CPU 资源池的资源混合调度；
- d) 宜支持对异构智算卡池的任务资源的混合调度；
- e) 宜支持 IB/RoCE 异构网络环境；
- f) 可支持相同计算任务在异构芯片的兼容性；
- g) 可支持对 NPU/FPGA 的兼容性；
- h) 可支持不同服务器品牌的兼容性。

7. 算力编排调度

7.1. 算力开通

算力资源开通主要基于调度策略和编排模板，实现算力资源的最终开通。

- a) 应支持算力资源的自动开通、下线；
- b) 应支持开通的事件提醒与日志审计；
- c) 应支持多租户资源隔离与权限管理能力，实现租户级、项目级、资源级等细粒度访问控制；
- d) 宜嵌入合规审计功能，实现开通流程的关键事件记录，如算力分配、资源就绪、异常告警；

- e) 宜提供可视化服务开通界面，允许用户自主选择算力类型、规模及部署位置（如本地/边缘节点）。

7.2. 算力编排

算力编排主要实现不同资源类型的组合模板，为算力调度开通提供支撑。

- a) 应支持图形化编排模板框架，通过通过图形化拖拽的方式定义编排模板；
- b) 应支持不同资源类型的混合编排，例如云主机、云网络、云存储等编排成一个服务模板；
- c) 应提供多模态、多版本模型的服务编排能力，支持不同模态和多版本模型的统一管理与编排；
- d) 应支持服务资源模板能力，实现服务及依赖资源间的部署开通；
- e) 应支持自有算力和第三方算力的统一编排和跨域调度协同能力；
- f) 宜支持千卡及万卡规模集群管理；
- g) 宜打造统一集约化的服务编排平台，实现从基础资源到 AI 应用开发的全流程服务，实现从资源调度、模型部署、应用开发和服务监控的一体化运营管理；
- h) 宜支持低代码/无代码的服务编排模式，提供可视化编排工具，拖拽式构建服务流程和 AI 应用；
- i) 宜提供一站式的服务托管与运维支持，提供从模型部署到应用上线的全托管服务。

7.3. 算力调度

算力调度基于算力感知为算力资源开通提供不同场景的调度策略，以保证不同需求场景的最佳调度决策。

应支持单节点的资源调度策略。

- a) 应支持碎片率优先的调度规则计算，实现根据节点碎片率进行优先调度的策略决策；
- b) 应支持成本优先的调度规则计算，实现根据最佳成本的调度策略决策；
- c) 应支持性价比优先的调度规则计算，实现按地域、按成本、按碎片率不同权重的计算最佳决策；
- d) 宜支持跨节点、跨集群、跨区域的资源调度策略；
- e) 宜支持负载感知调度策略，结合真实业务运行负载情况进行调度策略决策；
- f) 宜支持在离线业务混部调度策略，实现全局资源共享场景下的在离线业务混合部署调度策略决策；
- g) 宜具备区分训练和推理任务需求，提供多站点、多策略的算力调度能力，包括时延优先、算力优先、成本优先等多种策略算法；
- h) 宜支持抢占式任务调度侧，保证高优先级业务的资源需求；
- i) 宜具备 GPU 算力池化能力，支持多租户共享和细粒度分配。

7.4. 弹性扩缩容

实时感知业务负载并动态弹性扩缩容算力资源，在保障服务稳定性的同时实现资源利用率最大化与能耗成本最优化。

- a) 应具备根据任务负载自动扩缩容能力；
- b) 应支持根据实时业务负载变化，动态自动调整模型服务实例数量，以保证资源利用和服务稳定性；
- c) 宜支持基于自定义指标的弹性扩缩容策略；
- d) 宜支持提供灵活的扩缩容参数配置；
- e) 宜支持定时扩缩容策略。

8. 算力资源感知

算力感知主要支持对各云平台及各类纳管资源的全量数据实时采集，为算力调度提供数据分析依据。

- a) 应支持资源实例的数据实时采集，如容器 CPU 使用率、容器内存使用率等；
- b) 应支持智算卡资源的数据实时采集，如显存使用率、显卡数量等；
- c) 应支持宿主机资源的数据实时采集，如 CPU 使用率、内存使用率、剩余内存等；
- d) 应支持存储资源的数据实时采集，如存储总量、存储空间使用率、存储剩余容量等；
- e) 应支持网络资源的数据实时采集，如网络带宽利用率、网络端口流入流出速率、网络链路延迟等；
- f) 宜支持业务服务的数据实时采集，如业务 QPS、业务请求响应延迟等；
- g) 宜支持智算卡资源的碳足迹追踪与报告生成；
- h) 宜支持按区域的综合数据分析感知能力；
- i) 宜支持按集群的综合数据分析感知能力；
- j) 宜支持按业务的综合数据分析感知能力。

9. 算力运营能力开放

API 开放。

- a) 应支持对外标准的北向服务接口，如 RestAPI、websevice 等；
- b) 应提供标准化的 API 接口文档，包含详细的请求示例、响应码说明及调用限制，方便调用者快速接入模型服务；
- c) 应提供云原生 API 网关，支持 API 的高并发与调用，确保服务水平；
- d) 应通过 API 网关实现请求路由、负载均衡、熔断限流等管控策略，确保平台服务稳定性；
- e) 宜支持消息事件推送机制，如 Kafka、MQ 等；
- f) 宜提供交互式代码调试界面及示例代码，支持 Python、Java 等多种编程语言，便于在线调试验证。