

Q/KXY

云计算开源产业联盟技术文件

Q/KXY ICP005—2025

面向大模型的智算一体化解决方案 (DeepSeekV4 适配)

2025-01-20 发布

2025-02-14 实施

云计算开源产业联盟

目 次

目 次..... I

前 言..... I

面向大模型的智算一体化解决方案（DeepSeekV4 适配）.....1

1 范围..... 1

2 规范性引用文件..... 1

3 术语和定义..... 1

 3.1 智算服务 Intelligent computing services..... 1

 3.2 集群 colony..... 1

 3.3 服务器 server..... 1

4 缩略语..... 1

5 多模态训推一体机..... 2

 5.1 基础设施一体化能力..... 2

 5.1.1 计算能力..... 2

 5.1.2 储存能力..... 2

 5.1.3 网络能力..... 2

 5.2 平台应用一体化能力..... 3

 5.2.1 多模态框架支持度..... 3

 5.2.2 训推协同优化能力..... 3

 5.2.3 资源虚拟化能力..... 3

 5.3 管理一体化能力..... 3

 5.3.1 全栈监控能力..... 3

 5.3.2 安全能力..... 4

 5.4 DeepSeek V4 大模型专项适配能力..... 4

 5.4.1 完整训练适配能力..... 4

 5.4.2 微调与 SFT 适配能力..... 4

 5.4.3 DSV4 训推协同流转适配..... 4

 5.4.4 框架与工具链原生兼容..... 4

 5.4.5 DSV4 专项监控与告警..... 5

6 推理一体机..... 5

 6.1 基础设施一体化能力..... 5

 6.1.1 模型推理能力..... 5

 6.1.2 存储能力..... 6

 6.1.3 算力加速卡支持度..... 6

 6.2 平台应用一体化能力..... 6

 6.2.1 任务发布能力..... 6

 6.2.2 算力/作业调度能力..... 6

6.3 管理一体化能力 7

6.3.1 资源监控能力 7

6.3.2 安全能力 7

6.3.3 日志管理 7

6.4 DeepSeek V4 推理专项适配能力（新增章节） 7

6.4.1 DSV4 多规格模型部署适配 7

6.4.2 高性能推理加速适配 7

6.4.3 智能体与工具调用推理适配 7

6.4.4 DSV4 任务调度与弹性扩缩容 8

6.4.5 DSV4 专属运维与日志审计 8

前 言

本文件按照GB/T 1.1-2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别这些专利的责任。

本文件由云计算开源产业联盟提出并归口。

本文件起草单位：中国信息通信研究院。

本文件主要起草人：庄祎、郑立、韩思齐。

引 言

面向大模型的智算一体化解决方案作为评判各类具备大模型训练推理功能的“全栈式”人工智能设备的行业基准，推动行业的规范化与高质量发展。面向大模型的智算一体化解决方案针对大模型一体机供应方，为大模型一体机技术水平提供行业基准；针对需求方，提供安全可信、开箱即用的大模型一体机选型参考。

行业联盟

面向大模型的智算一体化解决方案（DeepSeekV4 适配）

1 范围

本文件定义了面向大模型的智算一体化解决方案的测试方法，覆盖多模态训推一体机、推理一体机和边缘一体机。

本文件同时适用于服务商提供的云服务产品以及硬件产品。

2 规范性引用文件

下列文件对于本文件的应用是必不可少的。凡是注日期的引用文件，仅所注日期的版本适用于本文件。凡是不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/T 5271.31-2006 信息技术 词汇 第 31 部分：人工智能 机器学习

3 术语和定义

下列术语和定义适用于本文件。

3.1 智算服务 Intelligent computing services

智算服务是智算产品能够提供服务的能力。。

3.2 集群 colony

集群是一种计算机系统，它通过一组松散集成的计算机软件/硬件连接起来高度紧密地协作完成计算工作。在某种意义上,他们可以被看作是一台计算机。

3.3 服务器 server

服务器是计算机的一种，它比普通计算机运行更快、负载更高、价格更贵。服务器在网络中为其它客户机（如PC机、智能手机、ATM等终端甚至是火车系统等大型设备）提供计算或者应用服务。服务器具有高速的CPU运算能力、长时间的可靠运行、强大的I/O外部数据吞吐能力以及更好的扩展性。

4 缩略语

下列缩略语适用于本标准：

ASIC：专用集成电路芯片（Application Specific Integrated Circuit）

FPGA：现场可编程阵列（Field Programmable Gate Array）

GPU：图形处理单元（Graphics Processing Unit）

DPU：数据处理单元（Data Processing Unit）

RDMA：远程内存直接访问（Remote Direct Memory Access）

5 多模态训推一体机

5.1 基础设施一体化能力

5.1.1 计算能力

1)配置多模态训推一体机的硬件资源，安装并配置相应的多模态训练与推理框架（如 TensorFlow、PyTorch、DeepSpeed、Transformers 等），准备多模态数据集。

2)测试单一模态（如文本或图像）任务的计算性能，分别测试文本分类、图像识别、语音识别等标准任务。记录每个任务的推理吞吐量、延迟、准确率等指标，评估系统在单一模态下的计算能力。

3)在多模态环境下进行训练和推理测试（例如，图像和文本联合训练的任务）。训练多模态模型，测试系统是否能够高效处理不同模态的数据输入，并且模型能够顺利收敛。

4)测试模型在多模态数据融合下的计算效率，记录多模态任务的训练和推理性能（如吞吐量、延迟、内存占用等）。

5.1.2 储存能力

检验支持分布式高速存储（ $\geq 100\text{GB/s}$ 带宽），具备横向扩展能力。

1)使用工具进行带宽测试，验证单一存储节点的读写带宽。在集群模式下，进行并行读写操作，测试存储系统的总带宽，确保在集群环境下达到规定的带宽要求。

2)模拟高并发场景（如多个数据节点同时进行读写操作），测试系统在并发访问情况下的带宽表现。记录每秒读写请求数，确保系统能维持高带宽下的低延迟，并保证数据一致性。

3)添加新的存储节点到现有集群，测试存储系统在横向扩展后的带宽表现，确保每增加一个节点带宽能够线性增长。测试集群扩展后，系统的存储容量和带宽是否能够按预期扩展，并且没有出现性能下降。

4)在多个存储节点间分配数据，进行读写操作，验证存储系统是否能够均匀分配负载，避免部分节点成为瓶颈。

5.1.3 网络能力

检验测试用例的软件栈信息与标准用例的一致性。

1)检查系统的网络软件栈版本和配置，确保其与标准测试用例的要求一致。

2)使用标准的网络性能测试用例（如 TCP 带宽测试、延迟测试、丢包率测试等），执行网络性能测试。

3)带宽测试：使用iperf或netperf等工具进行带宽测试，验证网络传输速率是否达到预期。

4)延迟测试：使用ping或iperf测试延迟，确认网络延迟符合要求。

5)丢包率测试：测试网络在高负载下的稳定性，记录丢包率是否在可接受范围内。

吞吐量测试：测试不同流量级别下的吞吐量，确保系统能够处理大流量并保持稳定。

5.2 平台应用一体化能力

5.2.1 多模态框架支持度

检验是否支持主流框架及多模态扩展。

1) 主流框架兼容性测试：

TensorFlow测试：验证系统是否能够加载并运行TensorFlow训练与推理任务，特别是图像分类、自然语言处理等标准任务。

PyTorch测试：验证PyTorch框架是否能够支持模型训练与推理，特别是多模态任务（如图像-文本联合模型、视觉问答等）。

MindSpore和MXNet测试：检查系统是否能运行MindSpore和MXNet框架中的常见多模态任务，如语音识别与图像生成的联合训练。

2) 多模态任务支持测试：测试框架中是否支持图像、文本、语音等不同模态的数据融合与联合训练。

3) 框架间兼容性测试：测试不同框架之间的兼容性与互操作性，如是否支持跨框架模型的加载和迁移。

5.2.2 训推协同优化能力

训练到推理延迟 $\leq 30\text{min}$ ，支持ONNX/TensorRT自动转换。

1) 配置训练和推理环境，准备标准模型和数据集，确保支持 ONNX/TensorRT 转换。

2) 训练模型并使用 ONNX/TensorRT 工具进行自动转换，记录训练到推理的总时间，确保 ≤ 30 分钟。

3) 测试转换后的推理模型，验证其推理性能、延迟和准确性，确保符合预期。

4) 多次重复训练-转换-推理流程，确保稳定性，分析性能瓶颈并生成报告。

5.2.3 资源虚拟化能力

支持GPU弹性取用，资源利用率 $\geq 80\%$ 。

1) 配置支持GPU虚拟化的环境，确保GPU资源可弹性取用。

2) 动态分配GPU资源，模拟多个任务并监控资源利用率，确保利用率 $\geq 80\%$ 。

3) 测试GPU资源的动态调整与回收，验证系统的弹性取用能力。

4) 实时监控和记录GPU使用情况，生成报告确保资源高效利用。

5.3 管理一体化能力

5.3.1 全栈监控能力

实现硬件层、框架层、应用层三级监控，告警响应时间 ≤ 30 秒。

1) 配置并启动硬件、框架、应用层的全栈监控系统，确保各层指标能够实时采集。

2) 模拟故障场景，验证系统是否能够在 30 秒内检测并触发告警。

3) 确保告警信息准确传递，并验证告警处理的响应时间符合要求。

4) 生成监控性能报告，确保全栈监控和告警响应时间达到预期。

5.3.2 安全能力

检验是否符合计算、存储、数据、网络安全能力要求。

- 1) 检查计算节点的访问控制和加密机制，确保计算过程中的数据安全。
- 2) 验证存储系统的加密措施，确保数据存储符合安全标准。
- 3) 测试数据传输过程中的加密协议（如 SSL/TLS），确保数据传输安全。
- 4) 检查网络安全防护（如防火墙、VPN），确保网络不受外部攻击，生成安全漏洞扫描报告。

5.4 DeepSeek V4 大模型专项适配能力

本小节规定多模态训推一体机对 DeepSeek V4 基座大模型、DeepSeek V4 多模态模型完整训练、微调、分布式集群、多模态融合、训推流转适配指标与测试方法。

5.4.1 完整训练适配能力

1) 分布式集群适配：支持 DeepSeek V4 大模型张量并行、流水线并行、数据并行混合分布式训练，兼容 DeepSeek 官方训练框架与 DeepSpeed 优化组件；搭建多机多卡集群，完成 DSV4 基座完整预训练 / 增量预训练，验证集群 RDMA 通信无阻塞、梯度同步稳定。

2) 超长上下文适配：支持 DSV4 原生超长上下文窗口训练，可配置 8k/32k/128k 上下文长度，测试长文本数据集训练收敛速度、显存占用、梯度丢失情况，保证长序列训练无精度衰减。

3) 多模态 DSV4 训练适配：支持 DeepSeek V4 图文多模态联合训练，兼容图像编码器、文本编码器跨模态融合训练流程，可加载图文配对数据集完成对齐训练，验证多模态损失正常收敛、图文生成任务准确率达标。

4) 显存优化适配：原生支持 DSV4 模型权重 / 梯度 / 优化器重计算、ZeRO 系列分片优化，测试大参数量 DSV4 模型单卡、多卡显存占用，同等硬件下可提升模型加载规模上限。

5.4.2 微调与 SFT 适配能力

1) 全参数微调、LoRA/QLoRA 轻量化微调双模式支持，适配 DSV4 基座、多模态分支微调；

2) 支持指令微调、工具调用微调、智能体多轮对话微调，加载 DSV4 官方标准 SFT 数据集完成微调，验证微调后模型指标提升符合基准；

3) 微调任务资源隔离：多租户并行开展 DSV4 微调任务时，GPU 虚拟化资源弹性调度，资源利用率不低于 80%，任务间无算力抢占冲突。

5.4.3 DSV4 训推协同流转适配

1) 支持 DSV4 训练权重一键导出为原生格式、ONNX、TensorRT、GGUF 量化格式，训练完成至推理部署全流程耗时≤30min，符合 5.2.2 通用训推延迟指标；

2) 量化转换适配：支持 DSV4 FP16/FP8/INT4/INT8 低比特量化，量化后推理精度损失控制在行业允许阈值内，吞吐量提升≥2 倍；

3) 多模态 DSV4 推理流转：图文联合训练模型可直接流转至多模态推理服务，无需重新拆分编码器，支持在线图文问答、文生图推理任务。

5.4.4 框架与工具链原生兼容

- 1) 原生兼容 DeepSeek 官方推理库、Transformers、vLLM、SGLang 主流加速框架，可直接加载官方发布 DSV4 权重；
- 2) 支持 DSV4 智能体插件、工具调用接口完整运行，可对接外部数据库、API 工具完成多轮函数调用推理；
- 3) 支持 DSV4 模型版本管理、权重快照保存、增量训练断点续训，中断后可快速恢复训练任务。

5.4.5 DSV4 专项监控与告警

- 1) 全栈监控新增 DSV4 专属指标：上下文序列长度占用、多模态编码显存开销、LoRA 微调权重加载量、分布式梯度同步耗时、量化推理精度波动；
- 2) 针对 DSV4 长文本 OOM、多模态显存溢出、分布式通信超时、微调梯度爆炸等场景设置专属告警，告警响应≤30 秒；
- 3) 支持按 DSV4 训练 / 微调 / 推理任务维度单独统计资源消耗，生成专项性能报表。

6 推理一体机

6.1 基础设施一体化能力

6.1.1 模型推理能力

检验是否具备模型推理能力。

- 1) 支持从云平台接收训练的模型；
- 2) 支持本地推理，包括离线批量推理、在线API推理等；
- 3) 支持对模型推理结果进行反馈和校对；
- 4) 支持将推理结果上传到云平台；
- 5) 支持根据推理反馈信息，提供模型表现的统计结果。

检验是否具备推理加速功能以及量化压缩技术。

- 1) 测试系统是否支持推理加速，并评估加速后的推理性能（如推理速度、延迟、吞吐量）。
- 2) 测试系统是否支持常见的量化方法（如权重量化、激活量化等），并验证量化后的模型大小、推理速度以及精度变化。
- 3) 比较未加速和加速后的推理性能，测试加速和量化技术对模型推理的加速效果，确保推理时间缩短且模型体积减小。

检验是否具备模型和知识库管理能力。

- 1) 支持模型生命周期管理，包括创建、上传、删除和查询等基本管理；
- 2) 支持模型镜像库管理，包括版本升级等；
- 3) 支持知识库迭代更新管理。

检验是否具备模型部署能力。

- 1) 支持根据用户配置将模型部署到推理一体机；
- 2) 可以进行模型批量部署；
- 3) 可以设定指定条件自动部署更新模型。

6.1.2 存储能力

检验存储方面可根据客户需求应用NFS网络存储或高性能独立存储。

- 1) 配置NFS网络存储与高性能独立存储设备，确保网络连接和存储设备可正常访问。
- 2) 挂载NFS存储，进行文件读取、写入及访问速度测试，验证存储的稳定性和性能。
- 3) 测试独立存储设备的读写速度、IOPS（每秒输入输出操作数）与延迟，确保满足高性能需求。
- 4) 在高负载下进行连续读写操作，检查存储设备在大数据量下的表现和稳定性。

6.1.3 算力加速卡支持度

检验是否支持多种算力加速卡，能够根据需求进行定制化组合适配。

- 1) 分别安装各类加速卡，启动系统并验证每种加速卡是否被操作系统和推理框架正确识别，确保驱动和硬件兼容性。
- 2) 在同一平台上组合多种加速卡（如 NVIDIA 和华为昇腾等），测试不同卡之间的兼容性与协同工作能力，检查是否存在性能瓶颈或资源冲突。
- 3) 在支持的加速卡上运行推理任务，测试不同加速卡的推理吞吐量、延迟及资源占用，评估加速卡在系统中的表现。
- 4) 根据特定需求定制组合加速卡，验证系统是否能够灵活配置和适配不同类型的加速卡，确保多样化应用场景的兼容性与性能。

6.2 平台应用一体化能力

6.2.1 任务发布能力

检验支持本机图形化界面、YAML、API对接第三方模型训推平台等模式的任务发布能力，支持裸金属容器方式发布AI模型、AI智能体应用，或发布渲染仿真求解器服务。

- 1) 配置本机图形化界面、YAML配置支持、API接口，确保系统能够接收任务发布请求，并搭建裸金属容器环境。
- 2) 通过图形化界面发布任务，选择模型、设置参数并启动任务，验证任务是否能够成功发布和执行。
- 3) 使用YAML配置文件定义任务参数，验证系统是否能够读取配置文件并成功发布任务，检查任务的执行情况。
- 4) 通过API接口调用发布任务，验证系统对第三方平台的接入能力，确保任务发布过程中的参数传递与调度无误。在裸金属环境下通过容器化部署AI模型或仿真求解器，检查发布的任务能否在容器中顺利执行，并进行性能评估。

6.2.2 算力/作业调度能力

检验是否支持各种GPU加速卡调度策略，为管理员提供完善的调度管理工具。

- 1) 配置多个GPU加速卡并安装调度管理工具，确保调度系统能够与不同类型的加速卡进行交互和管理。
- 2) 调度策略功能测试。

6.3 管理一体化能力

6.3.1 资源监控能力

检验是否能够提供主机CPU、内存、存储、网络、GPU加速卡使用率、显存、功耗、温度、风扇、等全面的监控指标，提供图形化界面，以及历史记录查询等能力。

1) 启动系统并通过图形化界面监控主机CPU、内存、存储、网络、GPU加速卡的实时使用情况。检查GPU加速卡的使用率、显存、功耗、温度、风扇转速等指标是否正确显示。

2) 测试每个监控指标的刷新频率和准确性，确保数据实时更新且没有延迟。

3) 测试历史数据查询功能，是否能够查询过去一段时间内的资源使用情况。

4) 测试图形化界面是否支持按时间、资源类型等条件进行查询，并能展示历史数据的趋势图或表格。

6.3.2 安全能力

1) 支持本地数据加密；

2) 支持数据传输加密；

3) 支持设置数据访问权限；

4) 支持端口白名单控制；

5) 支持网络异常行为感知；

6) 对重要的数据、配置有备份机制。

6.3.3 日志管理

1) 支持系统一体机硬件、系统、平台服务等日志采集、查询、分析；

2) 日志应记录所有类型的操作员（系统管理员、租户等）在系统上的操作行为；

3) 支持日志审计。

6.4 DeepSeek V4 推理专项适配能力（新增章节）

本节规范推理一体机部署、运行 DeepSeek V4 基座、多模态、量化版本推理服务的硬性适配指标与测试流程。

6.4.1 DSV4 多规格模型部署适配

1) 支持全尺寸 DSV4 大模型、中等参数量 DSV4、轻量化 DSV4 分支独立部署与多模型并行驻留推理；

2) 支持容器化打包 DSV4 推理服务，通过 YAML、API、可视化界面一键发布，支持批量滚动更新、灰度发布；

3) 支持 DSV4 多模态图文推理服务独立部署，图像编码、文本推理算力资源隔离调度。

6.4.2 高性能推理加速适配

1) 原生兼容 vLLM、SGLang、TensorRT-LLM、DeepSeek 官方推理加速引擎，针对 DSV4 PagedAttention 分页缓存优化，长文本推理吞吐量提升 ≥ 3 倍；

2) 全量化链路支持 DSV4 FP8/INT4/INT8 量化推理，支持动态量化、KV Cache 量化，降低显存占用，单机可承载更多并发对话；

3) 超长上下文推理适配：原生支持 DSV4 128k 上下文窗口在线推理，测试长文档问答、长代码解析场景下首包延迟、每 token 生成延迟、并发承载上限。

6.4.3 智能体与工具调用推理适配

- 1) 完整兼容 DSV4 内置函数调用、多轮智能体编排能力，可对接外部知识库、API、数据库完成检索增强生成（RAG）；
- 2) 支持 RAG+DSV4 联合推理链路，本地知识库向量库与 DSV4 推理服务无缝联动，支持批量文档问答、实时检索问答；
- 3) 多模态 DSV4 图文问答、图表解析、文生图推理全链路可用，支持图片上传、多图轮询输入推理。

6.4.4 DSV4 任务调度与弹性扩缩容

- 1) 调度系统识别 DSV4 推理任务专属资源需求，针对长上下文、多模态任务分配高显存加速卡；
- 2) 支持 DSV4 推理服务弹性扩缩，并发峰值自动新增算力实例，低峰自动回收 GPU 资源，整体资源利用率 $\geq 80\%$ ；
- 3) 多租户隔离：多业务同时运行 DSV4 推理服务时，显存、算力硬隔离，无任务之间延迟互相干扰。

6.4.5 DSV4 专属运维与日志审计

- 1) 日志模块独立采集 DSV4 推理全链路日志：用户输入、模型输出、token 消耗、上下文长度、量化参数、工具调用记录；
- 2) 支持按 DSV4 模型维度统计 QPS、平均延迟、显存峰值、错误率，生成推理性能报表；
- 3) 针对 DSV4 推理显存溢出、长文本超时、工具调用失败、量化精度异常配置独立告警策略。