

团 体 标 准

T/CCSA [xxxxx]—[xxxx]

智算云服务 Token 工程能力要求 总体框 架

The capability requirements for Token engineering in intelligent computing cloud
services — Overall framework

[点击此处添加与国际标准一致性程度的标识]

(工作组讨论稿)

2026 年 4 月

XXXX - - XX 发布

XXXX - XX - 实施

中华人民共和国工业和信息化部 发 布

目次

前 言 II

1 范围 1

2 规范性引用文件 1

3 术语和定义 1

4 缩略语 1

5 高性能计算云平台能力框架 错误！未定义书签。

6 高性能计算云平台能力分级 2

 6.1 分级概述 2

 6.2 分级规则 错误！未定义书签。

7 基础资源能力要求 2

 7.1 基础资源能力要求概述 3

 7.2 计算资源 3

 7.3 网络资源 4

 7.4 存储资源 4

8 平台能力要求 错误！未定义书签。

 8.1 平台能力要求概述 5

 8.2 运行环境 5

 8.3 作业管理 6

 8.4 集群管理 8

 8.5 数据管理 9

9 应用能力要求 错误！未定义书签。

 9.1 应用能力要求概述 10

 9.2 应用软件 10

 9.3 可视化能力 10

 9.4 用户接口 10

10 运维管理及安全能力要求 错误！未定义书签。

 10.1 用户管理 11

 10.2 日志审计 12

 10.3 监控告警 12

 10.4 计量计费 12

11 平台性能 错误！未定义书签。

 11.1 平台性能概述 13

 11.2 高性能集群综合性能 13

 11.3 高性能集群单项性能 13

前 言

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别这些专利的责任。

本文件由中国通信标准化协会提出并归口。

本文件起草单位：中国信息通信研究院

本文件主要起草人：

智算云服务 Token 工程能力要求 总体框架

1 范围

本文件规范了智算云服务中Token工程的能力要求，覆盖Token生产能力、Token流通编排能力、Token应用集成能力和Token治理能力，以及运维管理及安全能力要求。

本文件适用于公有云、私有云、混合云等部署模式下提供Token工程服务的云服务提供商及相关解决方案，为Token工厂服务的规划、建设、评估和优化提供统一的能力参考依据。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/T 1.1—2020 标准化工作导则 第1部分：标准化文件的结构和起草规则

3 术语和定义

下列术语和定义适用于本文件。

3.1

词元 token

词元（token）是大模型服务中模型处理文本的最小语义单元，是人工智能云服务的核心计量单元与能力载体。在中英文混编场景下，一个Token可对应一个汉字、一个英文单词的一部分或一个标点符。

3.2

Token 生产能力

Token生产能力是指平台通过智能算力调度、模型推理优化、资源编排等技术手段，高效生成Token的基础设施和工程能力。

3.3

Token 治理能力

Token 治理能力是指平台对 Token 服务的计量计费、服务质量保障、成本管控、合规管控等进行统一治理的能力。

4 缩略语

下列缩略语适用于本文件：

AIOps：智能运维(Artificial Intelligence for IT Operations)

API：应用编程接口(Application Programming Interface)

API Key：应用程序接口密钥(Application Programming Interface Key)

CI/CD：持续集成/持续交付(Continuous Integration/Continuous Delivery)

HPA：水平自动伸缩(Horizontal Pod Autoscaling)

IDE：集成开发环境(Integrated Development Environment)

MaaS：模型即服务(Model as a Service)

NPU：神经网络处理器(Neural Processing Unit)

QoS：服务质量(Quality of Service)

REST：表述性状态传递(Representational State Transfer)

SLA：服务等级协议(Service Level Agreement)

5 智算云服务 Token 工程能力框架

图1 智算云服务Token工程能力框架图

智算云服务Token工程能力框架包括Token生产能力、Token流通编排能力、Token应用集成能力和Token治理能力四个能力域，同时包含运维管理及安全能力。各能力域之间的关系如图1所示。

6 Token 生产能力要求

6.1 概述

Token生产能力是智算云服务Token工程的基础能力层，负责将智能算力和模型能力转化为可输出的Token服务，涵盖算力基础设施、推理运行时和Token生成等核心环节。

6.2 算力基础设施

Token生产所依赖的智算硬件资源，包括AI加速器(如GPU、NPU、FPGA等)、计算节点、高速网络和存储系统的建设与调度能力。

能力要求如下：

- a) 应支持多种类型的AI加速器，如GPU、NPU、FPGA等异构计算资源；
- b) 应支持AI加速器资源的池化管理与统一调度；
- c) 应支持计算节点的生命周期管理，包括创建、启停、删除等操作；
- d) 应支持多租户间的算力资源隔离和数据的隔离；
- e) 应支持Token生产集群的资源监控，包括加速器使用率、显存占用、温度等指标；
- f) 宜支持AI加速器资源的细粒度调度，如按卡、按算力比例进行分配；
- g) 宜支持AI加速器资源的弹性伸缩，能够根据Token生产需求动态调整资源规模；
- h) 宜支持跨集群、跨区域的算力资源统一管理与调度；

- i) 宜支持AI加速器资源的超分复用，提高大规模Token生产场景下的资源利用率；
- j) 宜支持AI加速器资源的动态迁移和热插拔；
- k) 宜支持在同一集群中对不同厂商、不同代际AI加速器的统一管理；
- l) 宜支持AI加速器资源的异构融合调度，同时管理GPU、NPU等多种加速器。

6.3 推理运行时

能力要求：

- a) 应支持主流大模型的一键部署，包括但不限于LLaMA、Qwen、DeepSeek系列等；
- b) 应支持模型推理引擎的配置和管理，能够对推理过程进行参数调优；
- c) 应支持模型版本管理，包括模型的上传、部署、版本回滚等；
- d) 应支持模型的并发推理，支持多请求的批量处理以提升Token吞吐量；
- e) 应支持推理过程的性能监控，包括请求时延、吞吐量、成功率等指标；
- f) 宜支持模型的多副本部署和负载均衡，提升Token生产的可用性和并发能力；
- g) 宜支持模型的动态扩缩容，能够根据Token请求负载自动增减模型实例；
- h) 宜支持模型推理性能的持续优化，如使用量化、剪枝等技术降低Token生产成本；
- i) 宜支持模型预热和缓存机制，减少首Token时延；
- j) 宜支持多种推理后端的选择和调度；
- k) 宜支持Speculative Decoding等推理加速技术，提升Token生成效率；
- l) 宜支持模型的零停机热更新，实现模型版本无缝升级；
- m) 宜支持多模型混合调度，根据Token请求特征智能选择最优模型；
- n) 宜支持模型推理的路由优化，实现模型推理成本的自动化化。

6.4 Token 生成

Token生成过程中的质量控制、生产效率和成本管理能力。

能力要求如下：

- a) 应支持Token的基础生成能力，能够稳定输出符合要求的Token序列；
- b) 应支持Token生成过程的参数配置，如温度、Top-P、Top-K等采样参数；
- c) 应支持流式Token生成，支持Server-Sent Events等方式逐Token返回；
- d) 应支持Token生成请求的并发处理；
- e) 应支持Token生产的基本质量保障，如结果一致性校验；
- f) 宜支持Token生产效率和成本的监控分析，能够统计每Token平均成本；
- g) 宜支持Token生产的服务质量保障，如差异化响应SLA配置；
- h) 宜支持Token生成过程中的可观测性，包括Token生产链路的全链路追踪；
- i) 宜支持Token质检能力，对生成Token的内容安全性和质量进行评估；
- j) 宜支持Token生产的速率控制，防止Token超发导致的系统压力；
- k) 宜支持Token生产的智能路由，根据成本、时延和质量目标自动选择最优生产路径；
- l) 宜支持Token生产的自动化预算控制，实现成本预测和动态调整；
- m) 宜支持Token生产质量的自动化评测与持续优化；
- n) 宜支持Token生产的跨集群协同调度，多集群实现Token生产的负载分发和容灾切换。

7 Token 流通编排能力要求

7.1 概述

Token流通编排能力是智算云服务Token工程的中枢能力层，负责Token及其关联凭证的全流程管理、多模型下的智能路由调度和跨服务Token流转控制。

7.2 凭证管理

对Token服务调用凭证(如API Key、Access Token等)的全生命周期管理能力。
能力要求如下：

- a) 应支持API Key的创建、查询、禁用、删除等生命周期管理；
- b) 应支持多租户间的API Key隔离，不同租户使用独立凭证；
- c) 应支持API Key的基本权限控制，如按模型、按配额进行权限划分；
- d) 应支持API Key的调用统计，包括调用次数、Token用量等；
- e) 应支持API Key的安全存储和加密传输；
- f) 宜支持API Key的自动轮转和过期管理；
- g) 宜支持API Key按场景、按应用维度的分级管理；
- h) 宜支持API Key调用流量的精细化控制，包括速率限制、并发控制等；
- i) 宜支持API Key调用统计的实时可视化；
- j) 宜支持API Key的异常调用检测和告警；
- k) 宜支持API Key调用行为的智能化分析，识别异常调用模式并自动处置；
- l) 宜支持多级API Key授权体系，支持组织内代理和委托调用；
- m) 宜支持API Key与统一身份认证系统的深度集成。

7.3 多模型路由调度

在多模型、多服务商场景下，对Token请求进行智能路由和调度分发的能力。
能力要求如下：

- a) 应支持多模型的统一接入和管理，能够对接不同模型服务提供商的API；
- b) 应支持基于模型能力类型的路由分发，如按文本生成、图像生成等任务类型路由；
- c) 应支持基于请求内容的路由配置，能够将特定场景的Token请求路由至指定模型；
- d) 应支持路由规则的基础配置和管理；
- e) 应支持路由分发的请求统计和日志记录；
- f) 宜支持基于Token成本的智能路由，能够在多个模型中选择成本最低的可用方案；
- g) 宜支持基于服务质量的路由，如选择响应最快、成功率最高的模型路径；
- h) 宜支持模型的灰度路由和流量切分，实现新模型的平滑上线；
- i) 宜支持路由规则的动态配置和热更新；
- j) 宜支持路由决策的可解释性，能够追溯请求的路由决策过程；
- k) 宜支持基于多目标优化的智能路由，综合考虑成本、时延、质量等因素进行决策；
- l) 宜支持基于历史调用数据的路由策略学习与自动优化；
- m) 宜支持模型的自动化评估和路由推荐，持续发现更优的模型组合；
- n) 宜支持跨云、跨服务商的混合路由，实现Token服务的最优组合。

7.4 Token 服务编排

将多个Token服务组合成完整业务流程的工作流编排能力。

能力要求如下：

- a) 应支持Token服务的基础编排能力，能够将多个模型调用串联形成工作流；
- b) 应支持工作流的创建、编辑、启停等生命周期管理；
- c) 应支持工作流的执行状态查看和日志查询；
- d) 应支持工作流的同步和异步执行模式；
- e) 应支持工作流执行过程中的参数传递和数据流转；
- f) 宜支持复杂工作流的编排，包括并行执行、条件分支、循环等控制结构；
- g) 宜支持工作流的可视化编排界面；
- h) 宜支持工作流模板的管理，包括模板的创建、存储和复用；
- i) 宜支持工作流的异常处理和自动重试机制；
- j) 宜支持工作流的版本管理和回滚；
- k) 宜支持工作流的动态编排，能够根据Token请求的上下文实时调整执行路径；
- l) 宜支持工作流的性能优化，自动发现并优化工作流中的瓶颈节点；
- m) 宜支持工作流的智能容错，在部分模型服务故障时自动选择替代路径；
- n) 宜支持工作流的跨Token工厂协同编排。

8 Token 应用集成能力要求

8.1 概述

Token应用集成能力是智算云服务Token工程的对外服务层，负责为上层应用提供便捷的Token服务调用方式，支撑智能体的运行和多渠道、多方式的集成接入。

8.2 智能体运行支撑

为面向任务的智能体应用提供运行环境，支撑其在Token驱动下完成任务的能力。

能力要求：

- a) 应支持智能体的基础运行，包括会话管理、上下文维护、任务执行循环等；
- b) 应支持智能体的工具调用能力，能够调用外部工具和API完成任务；
- c) 应支持智能体的多轮对话管理，维护对话历史和状态；
- d) 应支持智能体执行过程的可观测性，包括步骤记录和输出追踪；
- e) 应支持智能体的会话持久化和恢复；
- f) 宜支持智能体的并行执行和并发调度管理；
- g) 宜支持智能体执行上下文的智能管理，包括上下文压缩、检索增强等优化；
- h) 宜支持智能体执行预算控制，包括Token用量限制和执行时间限制；
- i) 宜支持智能体的状态持久化和故障恢复；
- j) 宜支持多智能体协同执行和角色分发；
- k) 宜支持智能体的自动化评测和性能对比；
- l) 宜支持智能体执行计划的智能生成和动态调整；
- m) 宜支持智能体的生命周期管理，包括创建、发布、监控和下线等全过程能力；

n) 宜支持智能体可观测的标准化接口，支持执行轨迹的捕获和分析。

8.3 应用集成与接入

为开发者提供便捷的Token服务集成方式，降低Token服务的调用门槛。

能力要求：

- a) 应提供标准化的REST API供应用调用Token服务；
- b) 应提供主流编程语言的SDK(如Python、Java、Go、Node.js等)；
- c) 应提供详细的API文档和快速入门指南；
- d) 应提供命令行接口(CLI)工具进行基础操作；
- e) 应支持Web控制台方式的交互接入；
- f) 宜提供低代码或零代码的集成方式，支持应用快速接入；
- g) 宜提供Webhook或回调机制，支持Token服务结果的异步通知；
- h) 宜提供丰富的代码示例和最佳实践模板；
- i) 宜支持第三方IDE的插件集成；
- j) 宜支持Token服务的自动化测试工具；
- k) 宜提供无服务器(Serverless)形态的Token服务调用方式；
- l) 宜支持Token服务的CI/CD集成，支持DevOps流程的自动化接入；
- m) 宜提供Token服务集成效果的可视化评估工具；
- n) 宜支持与流行应用开发平台的无缝集成。

9 Token 治理能力要求

9.1 概述

Token 治理能力是智算云服务 Token 工程的管理控制层，负责 Token 服务的计量计费、服务质量保障、成本管控和安全合规治理。

9.2 Token 可度量能力

能力要求如下：

- a) 应支持Token用量的按请求计量，记录每次调用的Token消耗量；
- b) 应支持Token用量按时间维度的统计分析(小时/日/月)；
- c) 应支持Token计费规则的配置，支持按Token数量计费；
- d) 应支持多租户维度的用量隔离和账单生成；
- e) 应支持用量的实时查询和账单下载；
- f) 宜支持多维度的计费模型，包括按Token数量、按请求次数、按套餐等计费模式；
- g) 宜支持Token用量和成本的实时监控与告警；
- h) 宜支持用量预算管理，支持设定用量上限和超额处理策略；
- i) 宜支持Token用量的细粒度分摊，支持按应用、模型、用户等多维度核算；
- j) 宜支持预付费和后付费两种计费模式；
- k) 宜支持Token成本的精细化分析和优化建议；

- l) 宜支持动态定价策略，根据模型成本、市场情况等实时调整Token价格；
- m) 宜支持Token用量的预测分析，帮助用户进行成本规划和资源预留；
- n) 宜支持跨租户的成本均摊和联合账单。

9.3 服务质量保障

对Token服务质量进行监控、评估和保障的能力。

能力要求：

- a) 应支持SLA的配置和管理，定义服务的可用性、响应时延等指标；
- b) 应支持Token服务可用性的监控，统计可用时间比例；
- c) 应支持Token生成的服务质量监控，包括首Token时延、每Token生成时延等；
- d) 应支持服务质量不达标的告警机制；
- e) 应支持Token服务质量报告的生成和导出；
- f) 宜支持多级别的服务质量分级，不同级别对应不同的Token生产性能指标；
- g) 宜支持服务质量保障的差异化配置，能够为不同租户或应用配置不同的SLA；
- h) 宜支持Token服务故障的自动切换和降级；
- i) 宜支持服务质量数据的实时Dashboard展示；
- j) 宜支持服务质量趋势分析和异常检测；
- k) 宜支持基于AI的服务质量预测和主动干预；
- l) 宜支持服务质量保障策略的自动化化，在满足SLA约束下最小化Token成本；
- m) 宜支持Token服务质量的端到端追踪和归因分析；
- n) 宜支持服务质量的第三方审计和认证。

9.4 成本管控

对Token服务成本进行预算管理、优化和控制的能力。

能力要求如下：

- a) 应支持Token服务成本的实时统计和查询；
- b) 应支持Token成本的按维度分析，包括按模型、按租户、按应用的精细化成本分析；
- c) 应支持Token成本的预算设置和超限告警；
- d) 应支持Token成本的配额管理，能够为租户设定Token用量上限；
- e) 应支持Token成本的计费明细导出；
- f) 宜支持Token成本的自动化优化建议，包括模型选择、推理配置调优等；
- g) 宜支持Token成本的自动控制策略，如成本超限时自动降级或限流；
- h) 宜支持Token成本的预测分析和趋势预警；
- i) 宜支持Token成本的同比环比分析，发现成本异常波动；
- j) 宜支持多场景、多业务线的成本分摊；
- k) 宜支持基于强化学习等智能算法的成本自动优化；
- l) 宜支持Token成本的全局最优调度，在全平台范围内平衡成本和性能；
- m) 宜支持Token成本的预测性预算管理，主动调整资源策略避免成本超支；
- n) 宜支持Token成本优化效果的量化评估和方案推荐。

9.5 安全合规

对Token服务的安全性和合规性进行保障的能力。

能力要求如下：

- a) 应支持Token服务的访问控制，确保只有授权用户可调用Token服务；
- b) 应支持Token流量的传输加密和安全存储；
- c) 应支持Token服务内容安全审核，防范有害内容生成；
- d) 应支持Token服务的操作审计日志记录；
- e) 应支持Token服务的隐私保护，如数据脱敏处理；
- f) 宜支持Token服务的内容安全策略配置，支持自定义审核规则；
- g) 宜支持Token服务的合规审计报告生成，满足行业监管要求；
- h) 宜支持Token服务的端到端加密通信链路；
- i) 宜支持Token数据的生命周期管理，包括数据留存、归档和销毁；
- j) 宜支持Token服务的安全合规自动化检查和告警；
- k) 宜支持Token服务的智能化安全防护，自动检测并阻断恶意Token请求；
- l) 宜支持Token服务调用行为的合规性自动评估和风险预警；
- m) 宜支持Token服务的零信任安全架构部署；
- n) 宜支持Token服务与监管报送系统的自动化对接。

10 运维管理及安全能力要求

10.1 用户管理

- a) 应支持用户权限管理，包括基于角色的访问控制，如添加、移除权限等；
- b) 应支持用户密码管理，包括密码修改、密码复杂度策略和重置；
- c) 应支持多租户隔离，不同租户的Token用量和资源相互隔离；

10.2 日志审计

- a) 应支持审计日志数据的完整性保护能力，确保日志数据的不可篡改性；
- b) 应支持日志数据的合规存储和满足数据留存周期要求；
- c) 应支持日志的集中存储和管理，便于检索和分析。

10.3 可观测性

11 性能要求

11.1 概述

11.2 Token 生产效率

Token生产效率是衡量Token生产能力的关键指标，反映Token生成的速度和资源利用效率。

- a) 每Token平均生成时延(毫秒/Token);
- b) 首Token响应时延(毫秒);
- c) Token生成吞吐量(Token数/秒);
- d) Token生成并发能力(最大并发请求数);
- e) 单位算力Token产出量(Token数/每秒每卡)。

11.3 Token 服务可用性

Token服务的可用性是保障用户业务连续性的关键指标。

- a) Token服务的请求成功率(成功请求/总请求);
- b) Token服务的月度可用性(可用时间/总时间);
- c) Token服务的故障恢复时间(分钟);
- d) Token服务的热备切换时间(秒)。