

中华人民共和国通信行业标准

YD/T XXXX—XXXX

代替XXXX

人工智能云 Token 工厂 全栈服务能力要求

Capability Requirements for Full-Stack Service of AI Cloud Token Factory

(草案)

XXXX – XX – XX 发布

XXXX – XX – XX 实施

目次

引 言 V

1 范围 1

2 规范性引用文件 1

3 术语和定义 1

 3.1 2

 词元 Token 2

 3.2 2

 人工智能云 AI Cloud 2

 3.3 2

 Token 工厂 Token Factory 2

 3.4 2

 智能体 Agent 2

4 缩略语 2

5 总体框架 2

 5.1 基础资源支撑层 3

 5.2 Token 生产能力层 3

 5.3 Token 流通能力层 3

 5.4 Token 应用能力层 3

 5.5 Token 工厂全栈效能治理能力 3

6 基础资源支撑能力要求 4

 6.1 通用资源管理能力要求 4

 6.2 计算资源能力要求 4

 6.3 存储资源能力要求 4

 6.4 网络资源能力要求 4

 6.5 集群资源能力要求 4

7 Token 生产能力要求 5

 7.1 模型兼容能力要求 5

 7.2 组件管理能力要求 5

 7.3 模型训练能力要求 5

 7.3.1 分布式训练能力要求 5

 7.3.2 增量训练能力要求 5

 7.3.3 模型精调能力要求 6

8 Token 流通能力要求 6

8.1 模型聚合推理部署能力要求	6
8.1.1 多模型聚合能力要求	6
8.1.2 AI 服务网关能力要求	6
8.1.3 在线推理交付能力要求	6
8.1.4 路由调度能力要求	7
8.1.5 推理优化引擎能力要求	7
8.1.6 SLA 保障能力要求	7
8.2 智能体开发与交付能力要求	7
8.2.1 Agent 编排能力要求	7
8.2.2 Prompt 复用能力要求	7
8.2.3 插件管理能力要求	8
8.2.4 应用模板能力要求	8
8.2.5 开发者工具链能力要求	8
9 Token 应用能力要求	8
9.1 多模态生成能力要求	8
9.2 Agent 生态能力要求	9
9.4 智能创作能力要求	9
10 Token 工厂全栈效能治理能力要求	9
10.1 端到端交付能力要求	9
10.2 应用场景最佳实践能力要求	10
10.3 全栈合规治理协同能力要求	10
10.4 全栈 Token 可观测能力要求	10
10.5 Token 计量管控能力要求	10
10.6 全链路稳定性保障能力要求	11

前 言

本文件按照GB/T 1.1—2020《标准化工作导则 第1部分：标准化文件的结构和起草规则》的规定起草。

请注意本文件的某些内容可能涉及专利。本文件的发布机构不承担识别这些专利的责任。

本文件由中国通信标准化协会提出。

本文件由中国通信标准化协会归口。

本文件起草单位：

本文件主要起草人：

引言

当前，大模型技术进入产业落地爆发期，人工智能（AI）应用在千行百业加速渗透。Token 作为大模型服务的核心计量单元与能力载体，其生产、流通、治理的全流程效能，直接决定了 AI 服务的成本、稳定性与可用性，成为人工智能产业发展的核心焦点。

当前行业内尚未形成统一的 Token 工厂服务能力标准，企业在 AI 应用落地过程中，普遍面临 Token 成本居高不下、多模型切换适配难、服务 SLA 保障不足、全流程合规管控缺失等痛点，严重制约大模型应用的规模化落地。为深入贯彻落实国家人工智能发展战略，推动人工智能云服务产业标准化、规范化发展，破解产业落地痛点，特制定本文件。

本文件首次构建了四层能力体系 + 一域治理能力的人工智能云 Token 工厂全栈服务能力框架，全面覆盖 Token 从生产、流通到应用、治理的全生命周期，为人工智能云服务提供商、AI 技术服务商、行业应用企业等主体，提供 Token 工厂建设、运营、评估、优化的统一规范和参考依据，引导产业高质量发展。。

人工智能云 Token 工厂 全栈服务能力要求

1 范围

本文件规定了人工智能云 Token 工厂全栈服务能力的总体框架、基础资源支撑能力要求、Token 生产能力要求、Token 流通能力要求、Token 应用能力要求、全栈效能治理能力要求，以及对应的评估方法。本文件适用于提供人工智能云服务的云厂商、AI 技术服务商、算力服务提供商等主体的 Token 工厂规划、设计、建设、运营与优化，也可作为行业用户选择 Token 工厂服务的参考依据，同时适用于第三方机构开展的 Token 工厂服务能力评估工作。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件：

GB/T 1.1-2020 标准化工作导则 第 1 部分：标准化文件的结构和起草规则

GB/T 31167-2014 信息技术 云计算 概念和架构

GB/T 35293-2017 信息技术 云计算 虚拟机管理通用要求

GB/T 44158-2024 信息技术 云计算 面向云原生的应用支撑平台功能要求

GB/T 22239-2019 信息安全技术 网络安全等级保护基本要求

GB/T 35273-2020 信息安全技术 个人信息安全规范

GB/T 42080-2022 信息技术 人工智能 安全能力成熟度模型

GB/T 41828-2022 信息技术 人工智能 模型服务描述要求

GB/T 38612-2020 信息技术 云计算 云服务运营通用要求

ISO/IEC 17788:2014 信息技术 云计算 概念和术语

ISO/IEC 17789:2014 信息技术 云计算 参考架构

ISO/IEC 27001:2013 信息技术 安全技术 信息安全管理体系 要求

ISO/IEC 27017:2015 信息技术 安全技术 云服务的信息安全控制实践守则

ISO/IEC 20000-1:2018 信息技术 服务管理

3 术语和定义

3.1

词元 Token

人工智能模型交互过程中，用于计量文本、图像、音频、视频等多模态输入输出内容的最小数据单元，是 AI 服务算力消耗、服务计费、流量管控、能力调度的核心计量单位与载体。

3.2

人工智能云 AI Cloud

面向人工智能应用全生命周期，提供算力、模型、开发工具、推理服务、运营管理等全栈能力的云计算服务模式，支撑大模型训练、推理、应用落地全流程需求。。

3.3

Token 工厂 Token Factory

以 Token 为核心锚点，覆盖 Token 生产、流通、应用、治理全生命周期，提供标准化、高性能、可管控的 Token 全栈服务的核心能力体系，是降低 AI 应用门槛、实现产业降本增效的核心支撑。

3.4

智能体 Agent

具备自主感知、决策、规划、执行能力的人工智能程序，可基于大模型能力完成复杂任务，是 Token 应用的核心载体。

4 缩略语

下列缩略语适用于本文件。

AI：人工智能（Artificial Intelligence）

LLM：大语言模型（Large Language Model）

RDMA：远程直接数据存取（Remote Direct Memory Access）

SLA：服务级别协议（Service Level Agreement）

API：应用程序编程接口（Application Programming Interface）

SDK：软件开发工具包（Software Development Kit）

RBAC：基于角色的访问控制（Role-Based Access Control）

GPU：图形处理器（Graphics Processing Unit）

CPU：中央处理器（Central Processing Unit）

5 总体框架

本文件构建了人工智能云 Token 工厂全栈服务能力的四层能力体系 + 一域治理能力总体框架，如图 1 所示。四层能力体系自下而上分别为：基础资源支撑层、Token 生产能力层、Token 流通能力

层、Token 应用能力层；一域治理能力为贯穿全流程的 Token 工厂全栈效能治理能力，实现对四层能力体系的全生命周期管控与优化。。




图 1 人工智能云 Token 工厂全栈服务能力总体框架

5.1 基础资源支撑层

基础资源支撑层是 Token 工厂的底层算力与资源底座，为 Token 全生命周期提供算力、存储、网络、集群等基础资源保障，包含通用资源管理能力与计算、存储、网络、集群四大专项资源能力。

5.2 Token 生产能力层

Token 生产能力层是 Token 工厂的核心生产环节，基于底层资源，通过模型适配、训练、精调等能力，实现 Token 的标准化、高性能生产，是 Token 供给的核心保障。

5.3 Token 流通能力层

Token 流通能力层是连接 Token 生产与 Token 应用的核心枢纽，通过模型推理部署、智能体开发交付两大核心模块，实现 Token 的高效流转、调度与服务化封装，支撑上层应用的灵活调用。

5.4 Token 应用能力层

Token 应用能力层是 Token 工厂面向最终业务场景的价值落地环节，基于底层 Token 能力，提供多模态生成、Agent 生态、知识库管理、智能创作等场景化应用能力，实现 Token 价值的业务转化。

5.5 Token 工厂全栈效能治理能力

Token 工厂全栈效能治理能力是贯穿 Token 工厂四层能力体系的全流程保障能力，覆盖端到端交付、场景实践、合规治理、可观测、计量管控、稳定性保障六大维度，实现 Token 全生命周期的一体化管控与效能优化。

6 基础资源支撑能力要求

基础资源支撑层为 Token 工厂提供底层资源保障，应具备通用资源管理能力，以及计算、存储、网络、集群四大专项资源能力，满足 Token 生产、流通、应用全流程的资源需求。

6.1 通用资源管理能力要求

- a) 应支持资源容器化能力，提供标准化容器运行环境，适配大模型训练、推理等任务的容器化部署需求，实现资源的轻量化、隔离化管理。
- b) 应支持弹性伸缩能力，可根据 Token 生产、推理任务的负载变化，自动扩缩容底层资源，保障业务高峰期的资源供给，降低低负载期的资源闲置。
- c) 应支持资源高可用能力，提供多副本、容灾备份、故障自动切换机制，保障底层资源的持续稳定运行，避免单点故障影响 Token 全链路服务。
- d) 应支持多云智管能力，实现跨云、跨区域、跨集群的资源统一纳管与调度，支持公共算力、专属算力、第三方算力的统一管理与协同调度。

6.2 计算资源能力要求

- a) 应支持芯片纳管能力，实现对 CPU、GPU、NPU 等各类 AI 计算芯片的统一纳管、状态监控与生命周期管理，适配国产计算芯片与主流通用计算芯片。
- b) 应支持异构兼容能力，实现不同架构、不同厂商的计算芯片的统一适配与协同调度，满足大模型训练、多模态生成等异构计算需求。

6.3 存储资源能力要求

- a) 应支持高性能存储能力，提供低延迟、高吞吐的存储服务，适配大模型训练、推理过程中的海量数据读写需求，满足 Token 生产过程中的数据访问性能要求。
- b) 应支持分布式存储能力，提供可横向扩展的分布式存储集群，实现训练数据、模型文件、业务数据的统一存储与管理，保障数据的可靠性与可用性。

6.4 网络资源能力要求

- a) 应支持高性能 RDMA 网络能力，提供 RDMA 高速网络传输服务，降低分布式训练、多节点推理的网络延迟，提升 Token 生产与流通的效率。
- b) 应支持带宽保障能力，可根据业务需求提供差异化的网络带宽资源预留与 QoS 保障，满足大模型训练、多模态生成等大流量业务的网络需求。

6.5 集群资源能力要求

- a) 应支持公共算力池建设，实现全域算力资源的池化整合，为多租户、多业务提供共享算力服务，提升资源利用率。
- b) 应支持专属算力建设，为高优先级、高安全需求的业务提供物理隔离、逻辑隔离的专属算力资源，保障业务的安全性与稳定性。

- c) 应支持第三方算力纳管，实现第三方厂商算力资源的统一接入、纳管与调度，拓展算力供给边界，满足业务弹性需求。

7 Token 生产能力要求

Token 生产能力层是 Token 工厂的核心生产环节，应具备模型兼容、组件管理、全流程模型训练与精调能力，实现 Token 的标准化、高性能、低成本生产。

7.1 模型兼容能力要求

- a) 应支持主流开源大模型、商用大模型、行业垂类模型的兼容适配，覆盖不同参数规模、不同模态的大语言模型、多模态模型。
- b) 应支持国产大模型的全面适配，实现国产模型的标准化接入、部署与运行，保障模型生产环节的自主可控。
- c) 应支持多版本模型的统一管理，实现模型版本的迭代、归档、回滚全生命周期管控，保障 Token 生产的一致性与稳定性。

7.2 组件管理能力要求

- a) 应提供 Token 生产全流程所需的标准化组件库，覆盖数据处理、模型训练、推理优化、效果评估等全环节组件，支持组件的一键调用与编排。
- b) 应支持自定义组件上传与管理，允许用户上传自研组件，实现组件的版本管理、权限管控与复用。
- c) 应支持组件的兼容性检测与性能优化，保障组件在不同模型、不同资源环境下的稳定运行。

7.3 模型训练能力要求

7.3.1 分布式训练能力要求

- a) 应支持大模型分布式训练能力，提供数据并行、张量并行、流水线并行等分布式训练策略，适配千亿级参数大模型的训练需求，提升 Token 生产的基础模型供给效率。
- b) 应支持分布式训练的容错机制，实现训练任务的断点续训、故障自动恢复，保障大规模训练任务的稳定运行。
- c) 应支持训练过程的实时监控与性能调优，可实时查看训练进度、算力利用率、损失函数等指标，提供训练策略优化建议。

7.3.2 增量训练能力要求

- a) 应支持大模型增量训练能力，基于行业垂类数据、业务场景数据，对基础大模型进行增量预训练，适配行业场景的 Token 生产需求。
- b) 应支持增量训练的轻量化配置，提供标准化的训练流程模板，降低增量训练的技术门槛。
- c) 应支持增量训练模型的效果评估，提供自动化的模型效果评测工具，保障增量训练后模型的 Token 生成质量。

7.3.3 模型精调能力要求

- a) 应支持全参数微调、LoRA 微调、QLoRA 微调等多种模型精调模式，适配不同业务场景、不同数据规模的精调需求。
- b) 应提供标准化的精调流程模板，支持用户快速完成精调数据处理、训练配置、任务下发、效果评估全流程操作。
- c) 应支持精调模型的统一管理与部署，实现精调模型与基础模型的联动调度，保障业务场景下的 Token 生成效果。

8 Token 流通能力要求

Token 流通能力层是连接 Token 生产与应用的核心枢纽，应具备模型聚合推理部署、智能体开发与交付两大核心能力，实现 Token 的高效流转、服务化封装与标准化交付。

8.1 模型聚合推理部署能力要求

模型聚合推理部署能力应实现多模型的统一纳管、推理优化与服务化交付，为上层应用提供标准化的 Token 调用服务，具体能力要求如下：

8.1.1 多模型聚合能力要求

- a) 应支持多厂商、多类型、多版本模型的统一纳管与聚合，提供统一的模型调用入口，实现多模型的一站式管理与调度。
- b) 应支持模型的统一适配与封装，将不同架构、不同接口的模型封装为标准化的调用服务，降低上层应用的多模型适配成本。
- c) 应支持模型的智能路由与负载均衡，根据业务需求、模型负载、调用成本，自动选择最优模型提供 Token 服务。

8.1.2 AI 服务网关能力要求

- a) 应提供统一的 AI 服务网关，实现 Token 调用请求的统一接入、鉴权、限流、转发，为上层应用提供标准化的 API 调用接口。
- b) 应支持请求的流量管控能力，提供限流、熔断、降级机制，保障高并发场景下 Token 服务的稳定运行。
- c) 应支持调用请求的全链路追踪，记录请求的流转路径、响应时间、调用结果，实现请求的可观测、可追溯。

8.1.3 在线推理交付能力要求

- a) 应支持大模型在线推理服务的一键部署与交付，提供标准化的推理服务实例，支持实时推理、流式推理等多种推理模式。
- b) 应支持推理服务的弹性扩缩容，根据调用请求量自动调整实例数量，保障推理服务的响应速度与资源利用率。

- c) 应支持推理服务的多实例部署与容灾备份，保障推理服务的高可用性，避免单点故障影响 Token 服务交付。

8.1.4 路由调度能力要求

- a) 应支持智能路由调度能力，根据 Token 调用请求的业务场景、优先级、成本要求、延迟要求，自动路由至最优的模型实例与算力节点。
- b) 应支持优先级调度、权重调度、最低延迟调度、最低成本调度等多种调度策略，满足不同业务场景的调度需求。
- c) 应支持调度策略的自定义配置，允许用户根据业务需求配置调度规则，实现个性化的路由调度。

8.1.5 推理优化引擎能力要求

- a) 应具备推理优化引擎，通过算子优化、模型量化、压缩加速、内存优化等技术，提升大模型推理效率，降低 Token 生成的延迟与算力成本。
- b) 应支持多框架、多模型的推理优化适配，覆盖主流深度学习框架与大模型架构，保障优化后的模型推理效果无损。
- c) 应支持推理优化策略的自动匹配，根据模型类型、硬件环境、业务需求，自动选择最优的优化方案。

8.1.6 SLA 保障能力要求

- a) 应支持分级 SLA 保障能力，为不同等级的租户、不同优先级的业务提供差异化的 SLA 服务承诺，包括服务可用性、响应延迟、调用成功率等指标。
- b) 应支持 SLA 指标的实时监控与统计，可实时查看 SLA 达成情况，对未达标的服务提供告警与优化建议。
- c) 应具备 SLA 违约的补偿机制，保障用户的合法权益。

8.2 智能体开发与交付能力要求

智能体开发与交付能力应提供低代码、可视化的智能体开发工具链，实现智能体的快速构建、编排、部署与交付，拓展 Token 的应用场景与价值，具体能力要求如下：

8.2.1 Agent 编排能力要求

- a) 应提供可视化的 Agent 编排能力，支持通过拖拽式操作完成智能体的任务规划、工具调用、逻辑流程编排，降低智能体开发门槛。
- b) 应支持多轮对话、任务拆解、自主决策等核心能力的配置，实现复杂业务场景的智能体编排。
- c) 应支持编排完成的智能体的一键调试、预览与发布，提升智能体开发效率。

8.2.2 Prompt 复用能力要求

- a) 应提供 Prompt 工程管理能力, 支持 Prompt 的创建、版本管理、分类存储与检索, 实现高质量 Prompt 的沉淀与复用。
- b) 应提供场景化 Prompt 模板库, 覆盖通用场景与行业垂类场景, 支持用户一键调用与自定义修改。
- c) 应支持 Prompt 效果的自动化评估与优化, 提供 Prompt 调优建议, 提升 Token 生成的质量与效果。

8.2.3 插件管理能力要求

- a) 应提供标准化的插件管理能力, 支持插件的开发、上传、审核、发布、下架全生命周期管理。
- b) 应提供丰富的内置插件库, 覆盖数据检索、工具调用、API 集成、业务系统对接等场景, 支持智能体的能力拓展。
- c) 应支持自定义插件的快速接入, 提供标准化的插件开发规范与 SDK, 降低插件开发门槛。

8.2.4 应用模板能力要求

- a) 应提供场景化的智能体应用模板库, 覆盖客服、营销、办公、研发、教育等通用场景与行业垂类场景, 支持用户一键生成应用。
- b) 应支持应用模板的自定义配置与二次开发, 允许用户根据业务需求修改模板内容, 适配个性化业务场景。
- c) 应支持模板的分享与复用, 实现优质应用模板的沉淀与推广。

8.2.5 开发者工具链能力要求

- a) 应提供完整的智能体开发者工具链, 包括开发调试工具、测试工具、部署工具、运维监控工具, 覆盖智能体开发全生命周期。
- b) 应提供标准化的 API 与 SDK, 支持开发者将智能体能力集成至第三方业务系统, 实现能力的灵活调用。
- c) 应提供开发者社区与文档支持, 为开发者提供开发指南、最佳实践、问题排查等支持服务。

9 Token 应用能力要求

Token 应用能力层是 Token 工厂面向业务场景的价值落地环节, 应具备多模态生成、Agent 生态、知识库管理、智能创作四大核心能力, 实现 Token 能力的业务转化与价值落地。

9.1 多模态生成能力要求

- a) 应支持文本、图像、音频、视频等多模态内容的生成能力, 覆盖多模态输入理解与多模态内容输出全流程。
- b) 应支持多模态生成内容的质量管控, 提供内容合规检测、效果评估、优化调整能力, 保障生成内容的准确性、合规性与可用性。
- c) 应支持多模态生成的个性化配置, 允许用户自定义生成风格、内容格式、生成参数, 适配不同业务场景的需求。

- d) 应支持长文本、高清图像、长音频、长视频等大尺寸内容的稳定生成，保障生成过程的连续性与生成效果的一致性。

9.2 Agent 生态能力要求

- a) 应构建开放的 Agent 生态体系，支持第三方开发者、厂商入驻，实现智能体的开发、发布、交易、运营全流程管理。
- b) 应提供 Agent 应用市场，实现智能体的分类展示、检索、下载、订阅，为用户提供丰富的智能体应用选择。
- c) 应支持 Agent 的权限管控、合规审核、效果评级，保障生态内智能体的安全性、合规性与可用性。
- d) 应提供生态激励机制，鼓励优质智能体的开发与沉淀，推动生态的良性发展。

9.3 知识库管理能力要求

- a) 应支持全类型知识库的构建能力，支持文本、文档、表格、图片、音视频等多类型数据的上传、解析、存储与管理。
- b) 应支持知识库的向量处理与检索能力，提供文本分块、向量嵌入、相似度检索、混合检索等能力，实现知识库内容的精准召回。
- c) 应支持知识库的版本管理、权限管控与增量更新，保障知识库内容的准确性、时效性与安全性。
- d) 应支持知识库与大模型、智能体的深度集成，实现检索增强生成（RAG），提升 Token 生成内容的准确性与行业适配性。
- e) 应支持多租户知识库隔离，保障不同租户的知识库数据安全与隐私。

9.4 智能创作能力要求

- a) 应支持全场景智能创作能力，覆盖文案写作、内容生成、剧本创作、代码生成、设计辅助等多种创作场景。
- b) 应提供创作全流程辅助能力，包括提纲生成、内容续写、润色优化、风格调整、合规校验等，提升创作效率与质量。
- c) 应支持自定义创作风格与模板，允许用户沉淀个性化的创作范式，实现标准化、规模化的内容创作。
- d) 应支持创作内容的版权管理、合规检测与溯源，保障创作内容的合规性与版权安全。

10 Token 工厂全栈效能治理能力要求

Token 工厂全栈效能治理能力是贯穿 Token 工厂四层能力体系的全流程保障能力，应具备端到端交付、应用场景最佳实践、全栈合规治理协同、全栈 Token 可观测、Token 计量管控、全链路稳定性保障六大核心能力，实现 Token 全生命周期的一体化管控与效能优化。

10.1 端到端交付能力要求

- a) 应支持 Token 工厂服务的端到端交付能力，覆盖从资源部署、模型配置、服务开发、上线运行、运维保障的全流程交付服务。

- b) 应提供标准化的交付流程与交付模板，针对不同行业、不同规模的用户，提供差异化的交付方案，降低用户的使用门槛。
- c) 应支持交付过程的全流程管控与可视化，可实时查看交付进度、交付质量，保障交付任务的按时完成。
- d) 应提供交付后的持续运营支持服务，包括技术培训、问题排查、性能优化等，保障用户业务的稳定运行。

10.2 应用场景最佳实践能力要求

- a) 应沉淀覆盖通用场景与行业垂类场景的 Token 工厂应用最佳实践，为不同行业、不同业务场景的用户提供落地参考。
- b) 应支持最佳实践的快速复制与落地，提供标准化的解决方案模板，帮助用户快速完成 Token 工厂服务的场景化落地。
- c) 应持续迭代优化最佳实践库，结合产业落地案例与技术发展，更新完善最佳实践内容，引领产业发展方向。

10.3 全栈合规治理协同能力要求

- a) 应具备全栈合规治理能力，覆盖 Token 生产、流通、应用全流程的合规管控，符合《生成式人工智能服务管理暂行办法》、网络安全等级保护等相关法律法规与监管要求。
- b) 应支持生成内容的全流程合规检测，包括输入内容审核、生成内容审核、敏感信息过滤、不良内容拦截，保障 Token 生成内容的合规性。
- c) 应支持数据安全与隐私保护，实现用户数据、训练数据、业务数据的全生命周期安全管控，符合个人信息保护相关法律法规要求。
- d) 应支持多主体合规治理协同，实现云厂商、模型厂商、应用服务商、用户的合规责任划分与协同管控，保障全链路合规。

10.4 全栈 Token 可观测能力要求

- a) 应具备全栈 Token 可观测能力，覆盖 Token 从生产、流通到应用的全链路指标监控、日志采集、链路追踪。
- b) 应支持多维度 Token 指标监控，包括 Token 生成量、调用量、消耗速率、延迟、成功率、成本等核心指标，提供可视化的监控仪表盘。
- c) 应支持全链路日志采集与分析，记录 Token 全生命周期的操作日志、运行日志、调用日志，实现问题的快速定位与追溯。
- d) 应支持分布式链路追踪，实现 Token 调用请求的全链路路径追踪，定位性能瓶颈与故障点。
- e) 应支持异常检测与智能告警，当 Token 相关指标出现异常时，可通过多渠道及时发出告警，并提供根因分析与处理建议。

10.5 Token 计量管控能力要求

- a) 应具备全流程 Token 计量能力，实现 Token 生成、调用、消耗的精准计量，计量精度应达到 Token 最小计量单位。

- b) 应支持多维度计量统计，可按租户、用户、模型、应用、时间等维度，统计 Token 的使用量、消耗量、费用等数据。
- c) 应支持自定义计量计费规则，可根据模型类型、Token 类型、调用场景、服务等级，配置差异化的计量计费策略。
- d) 应支持账单生成、明细查询、对账核算等功能，提供可视化的费用分析报表，帮助用户管控 Token 使用成本。
- e) 应支持 Token 配额管控，可按租户、用户、应用配置 Token 使用配额，实现配额预警、超额拦截，帮助用户实现成本可控。

10.6 全链路稳定性保障能力要求

- a) 应具备 Token 全链路稳定性保障能力，覆盖从底层资源、模型服务、网关调度到上层应用的全链路高可用保障。
- b) 应支持全链路故障检测、故障隔离、故障自动恢复能力，实现故障的快速定位与处置，降低故障影响范围与停机时间。
- c) 应支持流量管控与过载保护，通过限流、熔断、降级等机制，保障高并发场景下系统的稳定运行。
- d) 应支持容灾备份与多活部署，实现跨区域、跨集群的多活架构，保障极端场景下 Token 服务的持续可用。
- e) 应支持全链路压测能力，可模拟高并发、大流量场景，对系统性能进行压测，提前发现性能瓶颈并优化。